중급2 프로젝트

공유오피스 무료 체험 운영 최적화

수요 및 결제 전환 분석

기간	2026.09.11 ~ 2026.09.29	
작성자	클래스 불균형팀	곽수연 김채현 박고은 송용진 신예원

목차 Contents

분석 배경 및 목적 01

문제 정의 02

전처리 03

EDA 04

모델링 과정 및 결과 05

핵심 인사이트 & 실행 전략 06

한계 07

SECTION 01

Deep Dive & Objective

분석 배경 및 목적

분석 배경

> 무료체험은 고객이 실제 공간과 서비스를 경험한 후 유료 이용 여부를 결정하는 핵심 단계

체험 기간의 이용 방식

언제·얼마나·몇 번 이용했는가

→

결제 전환과의 연결

이용 방식이 결제에 영향을 주는가

→

운영 개선의 근거

이용 기록으로 체험 설계 재검토

활용 변수

지점 정보, 입퇴실 시간, 체류 시간, 방문 일수, 결제 여부 등

- ☑ 무료체험 수요의 시간적 · 공간적 패턴 분석
- ☑ 결제 전환과 관련된 이용 특성 파악

분석 목적

수요 예측에서 출발해 결제 전환의 핵심 신호를 찾고, 무료체험 운영 개선안으로 연결한다

STEP 1 수요 예측

요일 · 시간대별 무료체험
동시 체류 인원을 예측

- 수요가 집중되는 시간과
  상대적으로 여유로운 시간을 사전 파악

STEP 2 전환 예측

어떤 요인이 결제 전환에
기여하는지 확인

- 1차 분석에서 도출한 수요 정보와
  체류시간 · 방문일수 · 재방문 여부 등
  이용행태를 결합

STEP 3 개선안 도출

두 단계의 모델링에서 얻은
신호를 운영 방안으로

- 실제 무료체험 운영에 활용할 수 있는
  데이터 기반 개선안 도출

SECTION 02

Problem Definition

문제 정의

문제 정의

지점별/요일별/시간대별 무료 체험 동시 체류 인원을 예측할 수 있는가?

시간대별 수요 수준과 체류시간/방문일수/재방문 여부 등의 이용행태는 결제 전환과 어떤 관계가 있는가?

분석 결과를 무료체험 시간 구성, 재방문 유도 및 전환 전략에 어떻게 활용할 수 있는가?

무료체험 수요를 사전에 파악하고, 결제 전환과 관련된 주요 이용 특성을 확인하여
무료체험 운영 및 전환 전략에 활용할 수 있는 근거를 마련하고자 한다.

SECTION 03

Data Preprocessing

데이터 전처리

데이터 전처리

trial_visit_info 원본
11,477 행

>

중복 · 이상치 제거
11,403 행

>

결측 대체 후 병합
11,317 행

>

자정 분할 세션 복원
10,400 행

>

두 지점 겹침 정제
10,402 행

주요 처리 내역

시차 보정	trial_access_log 의 cdate가 UTC 기준 → +9시간 KST 변환
중복 제거	5개 테이블 내 중복행 470건 제거
이상치 제거	체류 60초 미만 · 입퇴실 역전 제거
결측 대체	입·퇴실 결측을 출입로그 요약값으로 대체, 그 외 대체 불가한 결측치 제거
테이블 병합	trial_visit_info + trial_register + trial_payment + site_area → 마스터테이블 생성
자정 분할 세션 복원	자정을 기준으로 2건으로 분리된 세션 1개의 세션으로 통합
두 지점 겹침 정제	한 사람이 같은 시각에 두 지점에 동시에 있는 것으로 기록된 행 정제

데이터 전처리

trial_visit_info 원본	중복 · 이상치 제거	결측 대체 후 병합	자정 분할 세션 복원	두 지점 겹침 정제
11,477 행	**11,403** 행	**11,317** 행	**10,400** 행	**10,402** 행

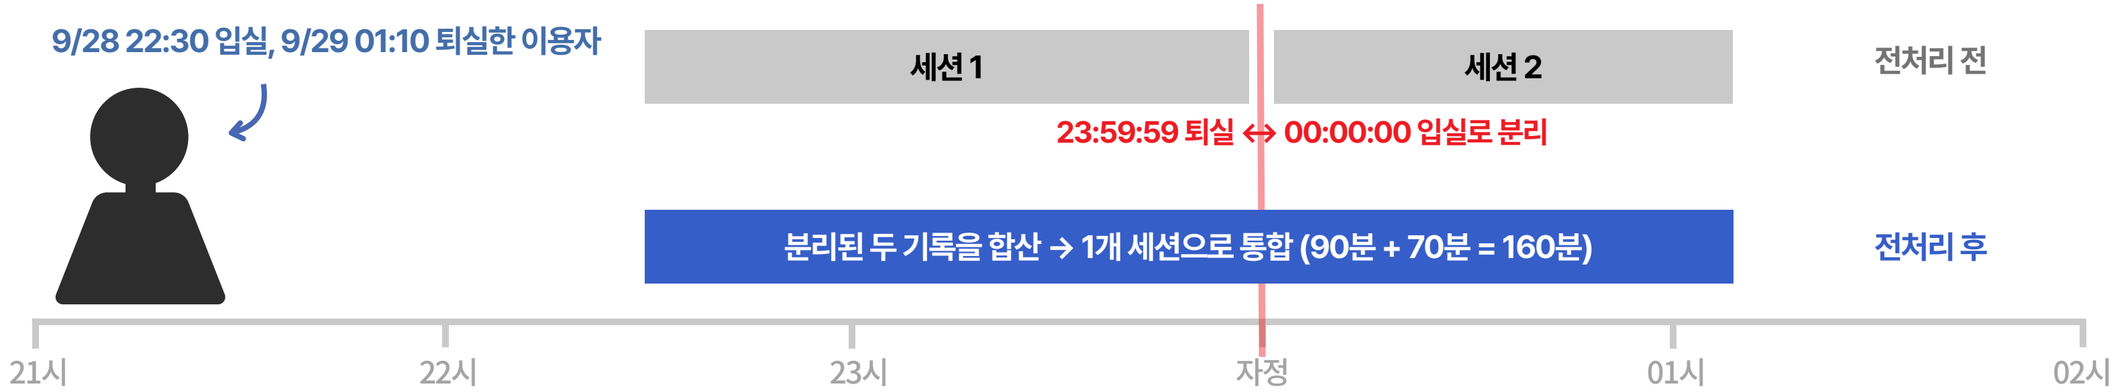
주요 처리 내역

시차 보정	trial_access_log 의 cdate가 UTC 기준 → +9시간 KST 변환
중복 제거	5개 테이블 내 중복행 470건 제거
이상치 제거	체류 60초 미만 · 입퇴실 역전 제거
결측 대체	입·퇴실 결측을 출입로그 요약값으로 대체, 그 외 대체 불가한 결측치 제거
테이블 병합	trial_visit_info + trial_register + trial_payment + site_area → 마스터테이블 생성
자정 분할 세션 복원	자정을 기준으로 2건으로 분리된 세션 1개의 세션으로 통합
두 지점 겹침 정제	한 사람이 같은 시각에 두 지점에 동시에 있는 것으로 기록된 행 정제

데이터 전처리 - 자정 분할 세션 복원

11,317행 중 00:00:00 입실 **738행**, 23:59:59 퇴실 **727행**, 입퇴실 모두 해당 **114행**

총 **1,351행** 발견



복원 **자정 1회 통과**

전처리 전	868행
전처리 후	434행

제거 **자정 2~3회 통과**

전처리 전	250행
전처리 후	퇴실 태그 누락으로 판단, 전량 삭제

제거 **짝 없는 단독 로그**

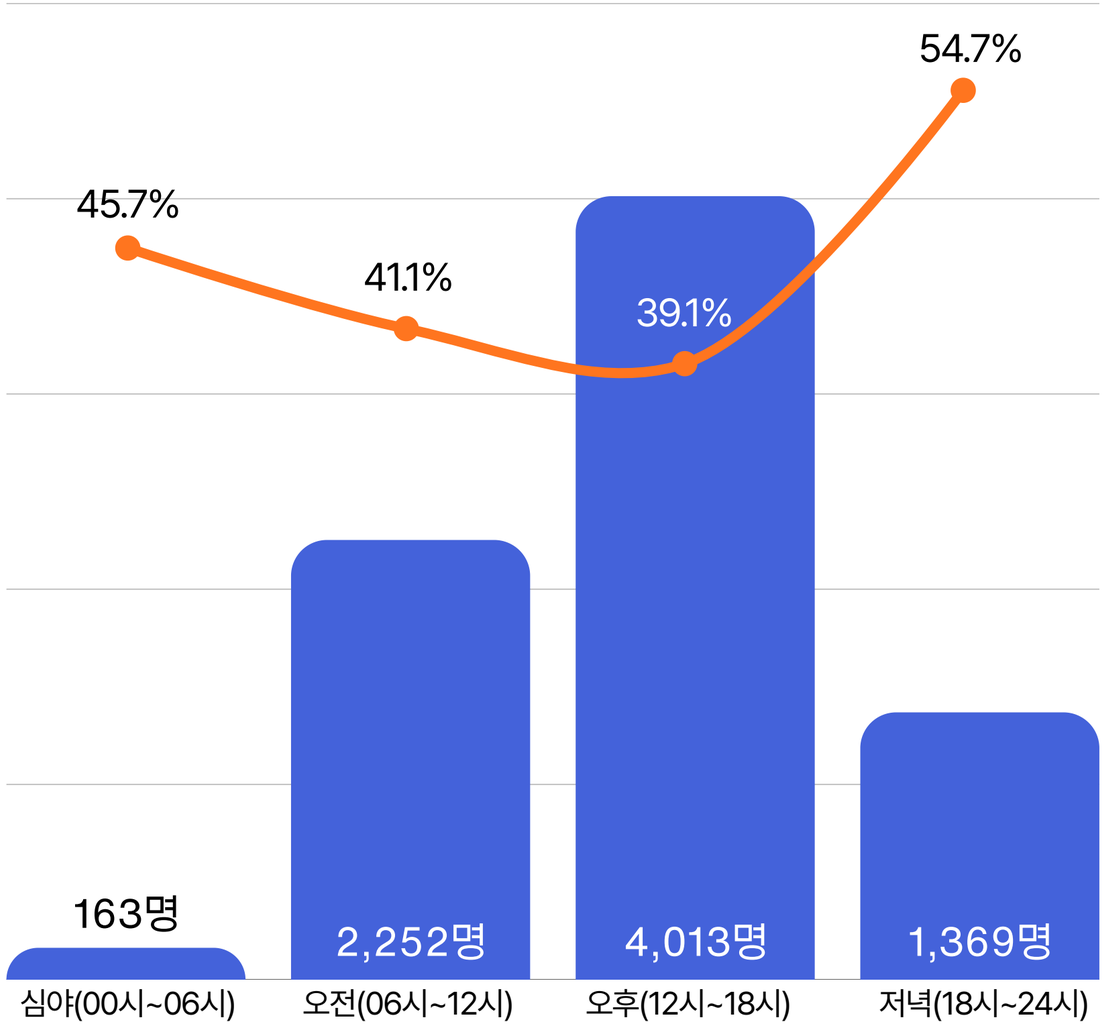
전처리 전	233행
전처리 후	전후 관계 입증 불가로 전량 삭제

SECTION 04

EDA

분석 결과

시간대별 이용패턴 & 결제 전환율



이용량이 가장 많은 시간대의 전환율이 가장 낮다

오후 12~18시 최저

이용량 51.5% (4,013명)

전환율 39.1%

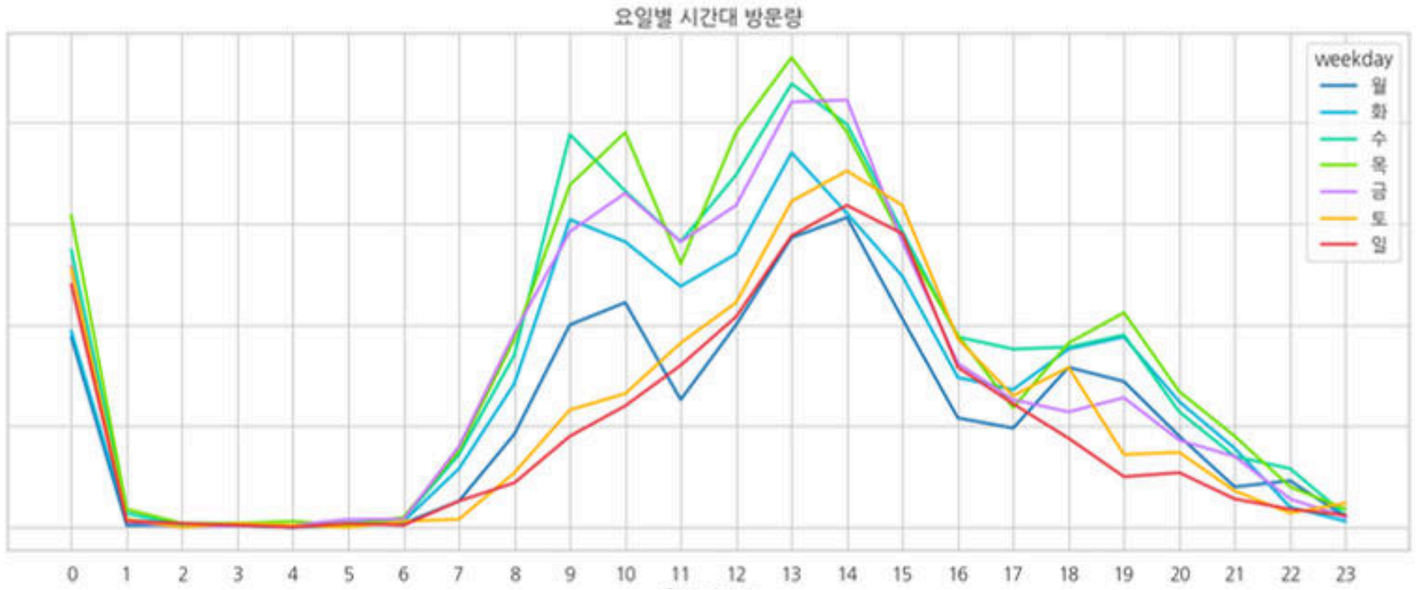
저녁 18~24시 최고

이용량 17.6% (1,369명)

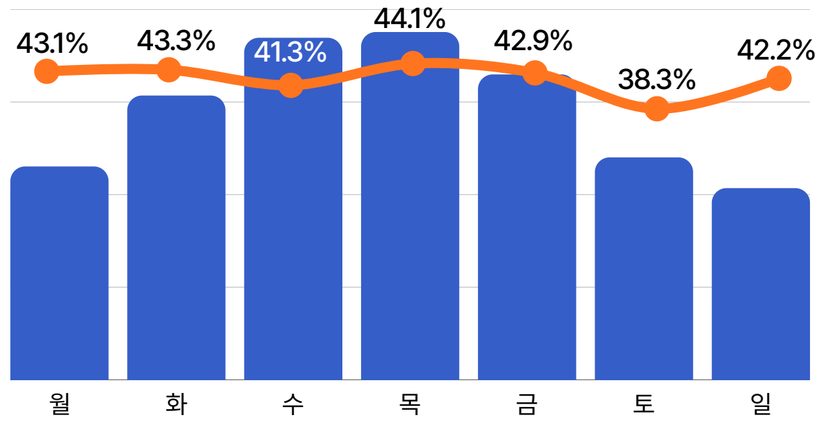
전환율 54.7%

단순히 수요가 많은 시간대가 반드시 전환에 유리하다고 보기는 어렵다.

요일별 이용 패턴 & 결제 전환율



요일별 이용량 및 결제 전환율



이용량은 요일별로 다르지만, 결제 전환율은 요일과 무관하다

평일 월~금

- 목 > 수 > 금 순서로 이용량이 많음
- 주로 오후 12~15시 사이 압도적인 피크 형성

주말 토 · 일

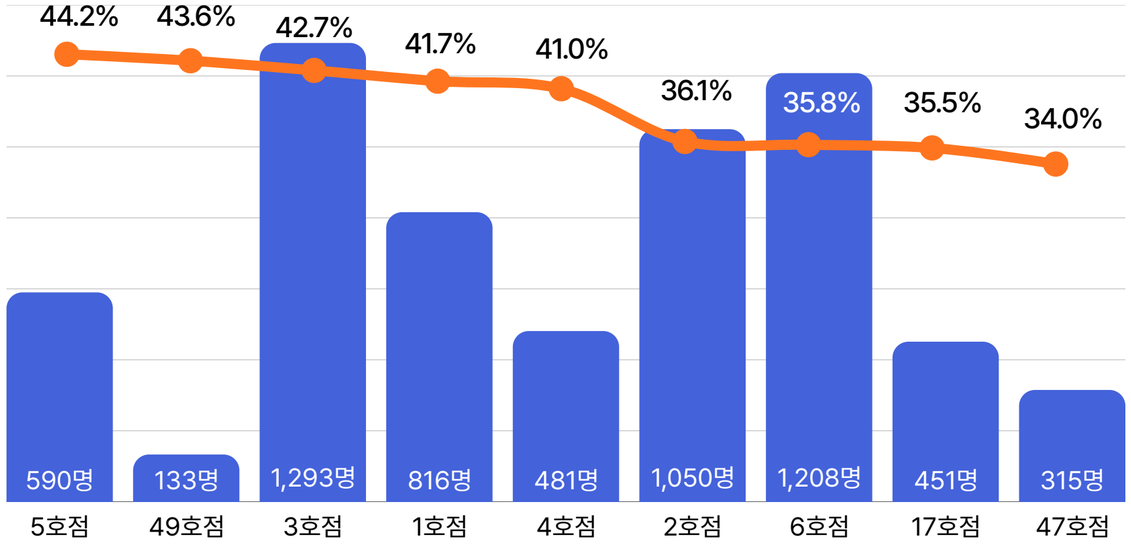
- 전체적으로 평일보다 이용량이 낮은 경향
- 평일과 달리 14~15시 1시간 가량 피크 형성

전환율 요일 무관

- 38.3 ~ 44.1%, 격차 5.8%p
- 이용량이 많은 수 · 목 · 금도 큰 차이를 보이지 않음

지점별 이용 패턴 & 결제 전환율

주 이용 지점별 고유 유저 수 및 결제 전환율



지점 면적별 결제 전환율



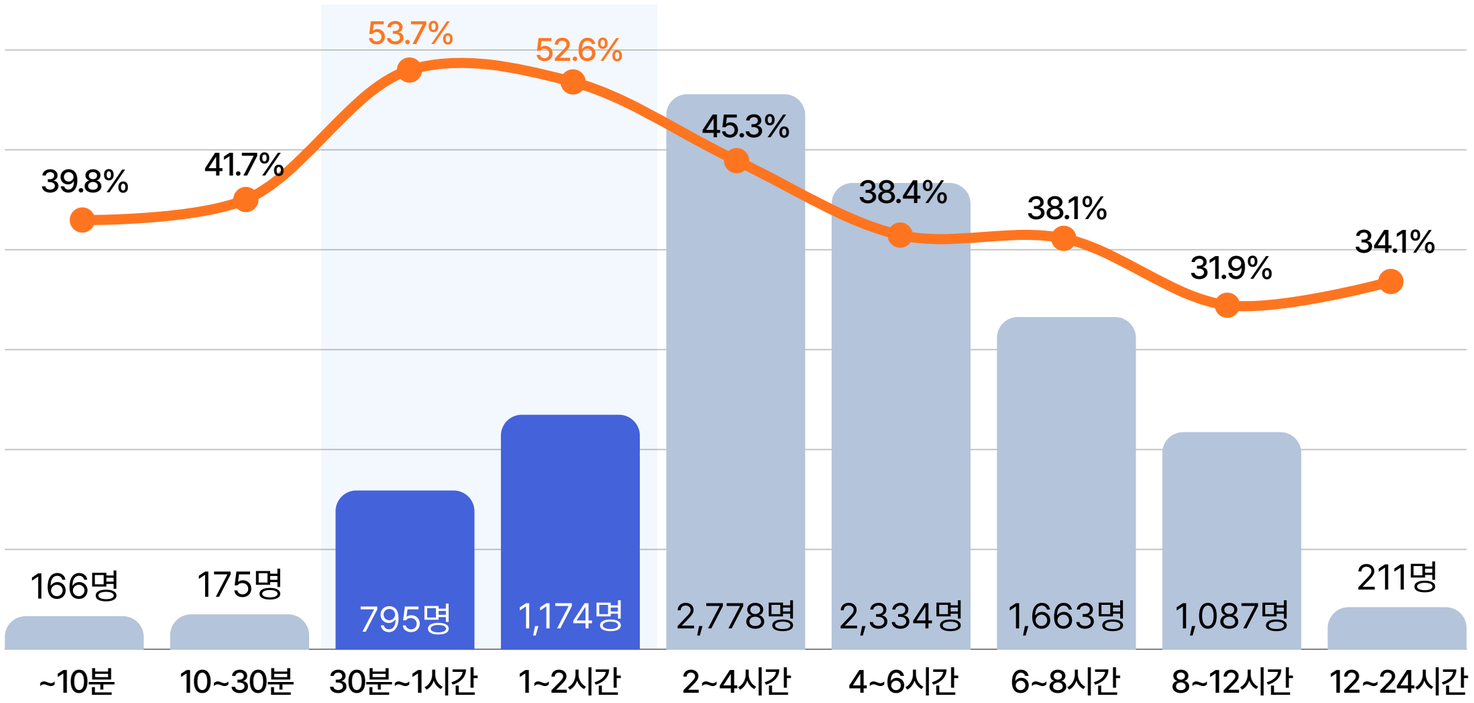
지점 이용 다양성별 결제 전환율



표면적으로는 주 이용 지점별 결제 전환율 차이가 존재하는 것처럼 보이나, 운영일수·이용자 구성·체류시간·지점 특성 등을 함께 고려하면 지점 자체의 품질 차이로 보기는 어렵다.

지점별 결제 전환율 영향 이용자의 행동 패턴 > 각 지점의 물리적 특성

체류시간 분포 & 결제 전환율



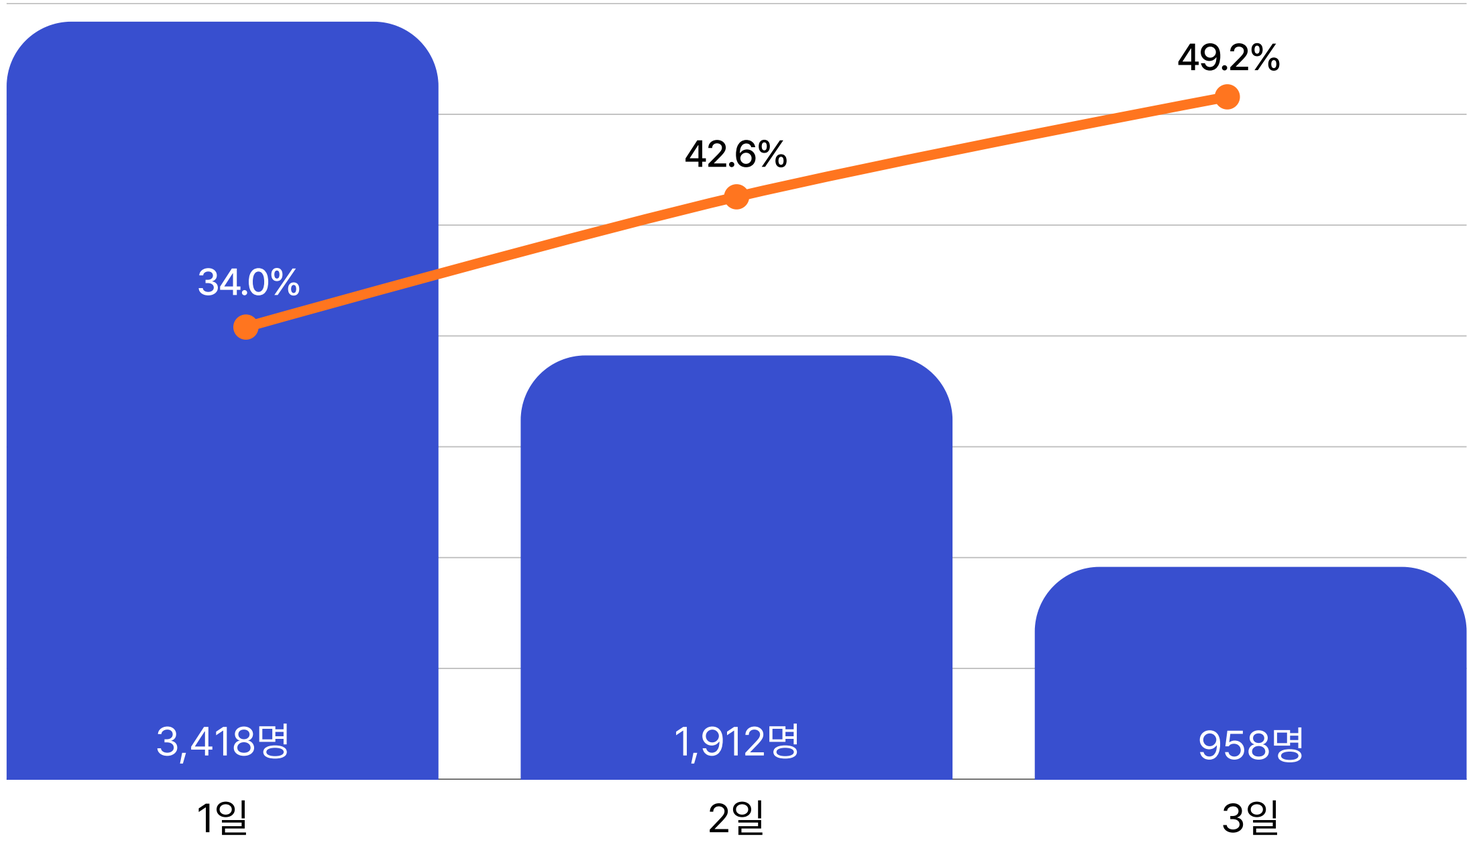
체류시간이 길수록 결제 전환율은 감소한다

최고	30분~1시간	53.7%
2위	1~2시간	52.6%
최저	8~12시간	31.9%
최다 이용	2~4시간	45.3%

최고 vs 최저 격차 21.8%p

체류시간과 결제 전환율 사이의 유의미한 관계 확인.
이용량은 2~4시간 (2,778건) 에 가장 몰려 있지만 전환율은 **45.3%**에 그친 반면, **30분~1시간 (53.7%)** 과 **1~2시간 (52.6%)** 구간에서 가장 높았다.

방문 일수별 이용 패턴 & 결제 전환율



체험기간을 끝까지 쓴 유저일수록 결제 전환율이 높았다

1 일 방문	3,418 명	34.0%
2 일 방문	1,912 명	42.6%
3 일 방문	958명	49.2%

3 일 vs 1 일 격차 15.2%p

무료체험 3일을 모두 이용한 유저의 전환율은 49.2%로 1 일만 방문한 유저 (34.0%) 보다 15.2%p 높다.

SECTION 05

Modeling Process & Results

모델링 과정 및 결과 분석

4단계 모델링 로드맵

STEP 1

수요예측

회귀 모델 → 분류 모델

1시간 단위 예측 시도 →
4구간 등급분류로 전환

STEP 2

전환예측

2차 모델링

등급의 한계 확인 →
결제전환예측으로 확장

STEP 3

개선시도

성능 개선

변수추가·튜닝·
모델비교·임계값조정

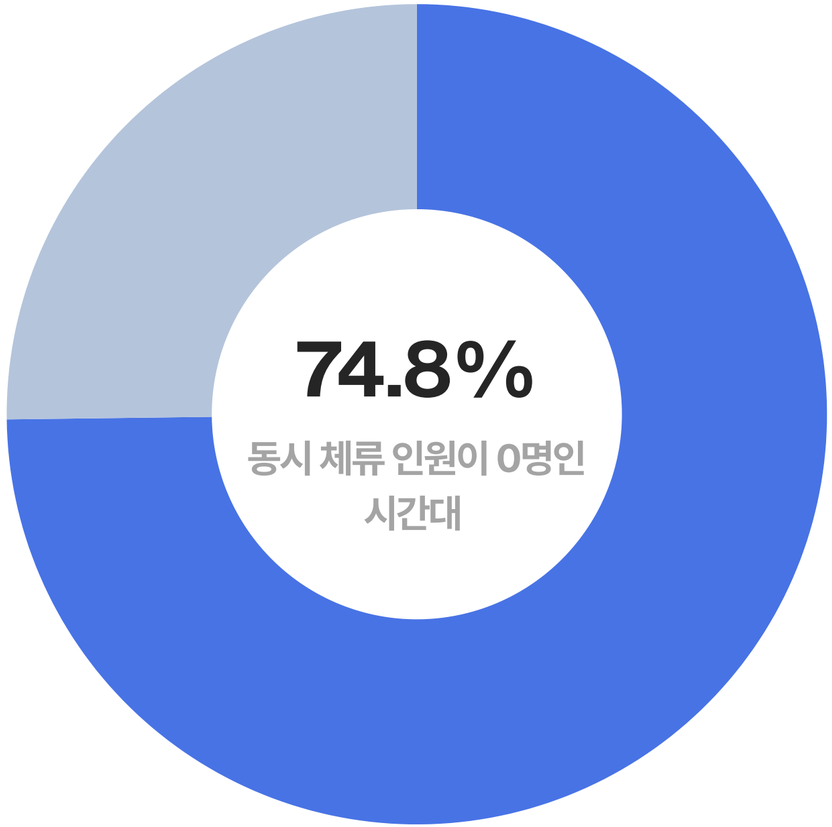
STEP 4

핵심발견

체류시간

체류시간 중요도 및
변화량 효과 검증

1시간 단위 수요 예측의 한계



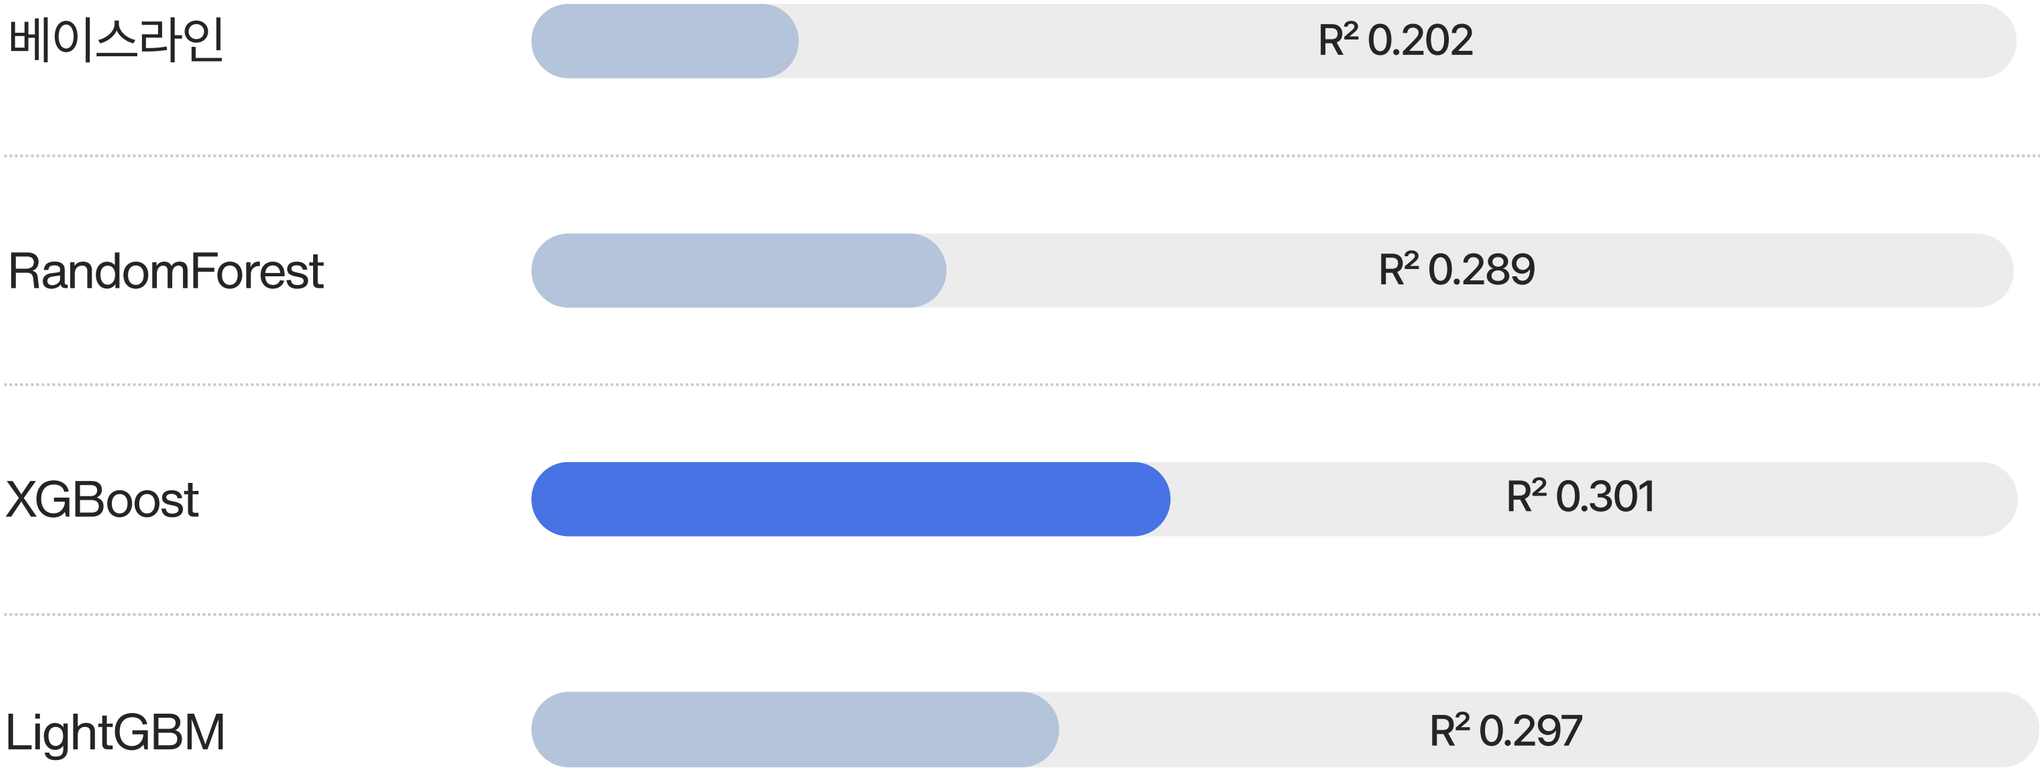
"1시간 단위로 동시 체류 인원 예측했으나
관측치 74.8%가 0명"

R^2 0.10~0.20로 신호 부족

해상도를 4구간(야간·오전·오후·저녁)으로 확장

4구간 확장을 통한 예측력 개선

야간(0~6시) · 오전(6~12시) · 오후(12~18시) · 저녁(18~24시), 4개 시간대로 재구성



4구간 확장 후 XGBoost의 R^2가 0.301로 가장 높았지만, 정밀한 인원 예측에는 여전히 한계가 있었다.

일 단위 확장과 예측력 재검토

4구간(시간대) 단위였던 예측을 일(day) 단위로 확장해 재구성

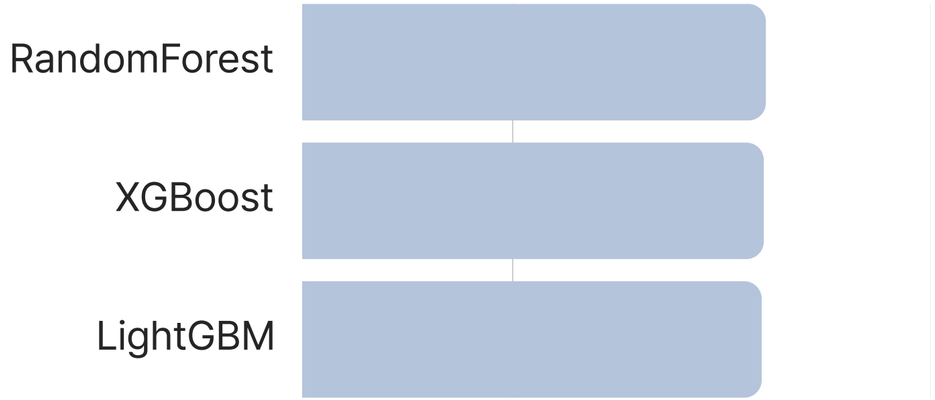
베이스라인	R^2 0.064
RandomForest	R^2 0.215
XGBoost	R^2 0.222
LightGBM	R^2 0.209

일 단위로 확장해도 최고 R^2는 0.222로, 4구간 예측보다 낮았다.

수요 등급화를 통한 예측 안정화

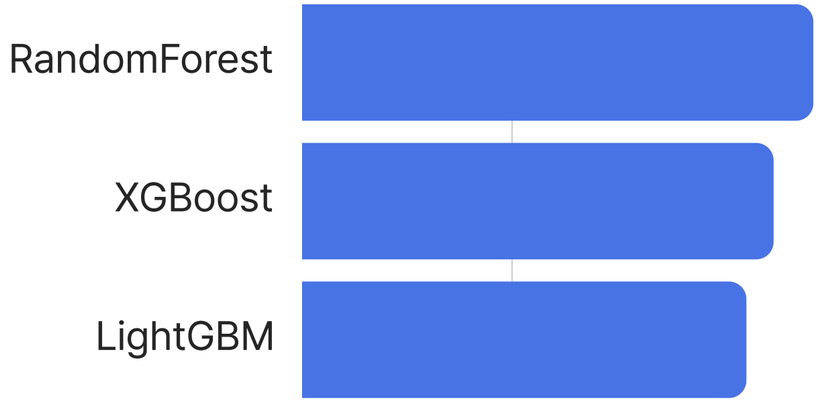
0.25명 미만=수요없음 · 0.25명~지점별 high_threshold=보통 · high_threshold(0이 아닌 값의 75분위수, 최소 1.0) 이상=높음

1시간 단위 등급 분류



최고 Macro F1 0.521(RandomForest)

4구간 등급 분류



최고 Macro F1 0.544(RandomForest)

4구간 분류에서 Random Forest의 Macro F1은 0.544, 높음 수요 Recall은 54.2%로 가장 안정적이었다.

그런데, 등급분류 예측만으로는

“그래서 회사가 무엇을 해야 하는가“까지는 답할 수 없었다.

2차 모델링 계획

실제 방문 기록으로 산출한 이용도 등급 변수로 활용해
유료 전환(is_payment) 예측으로 분석을 확장

0.544

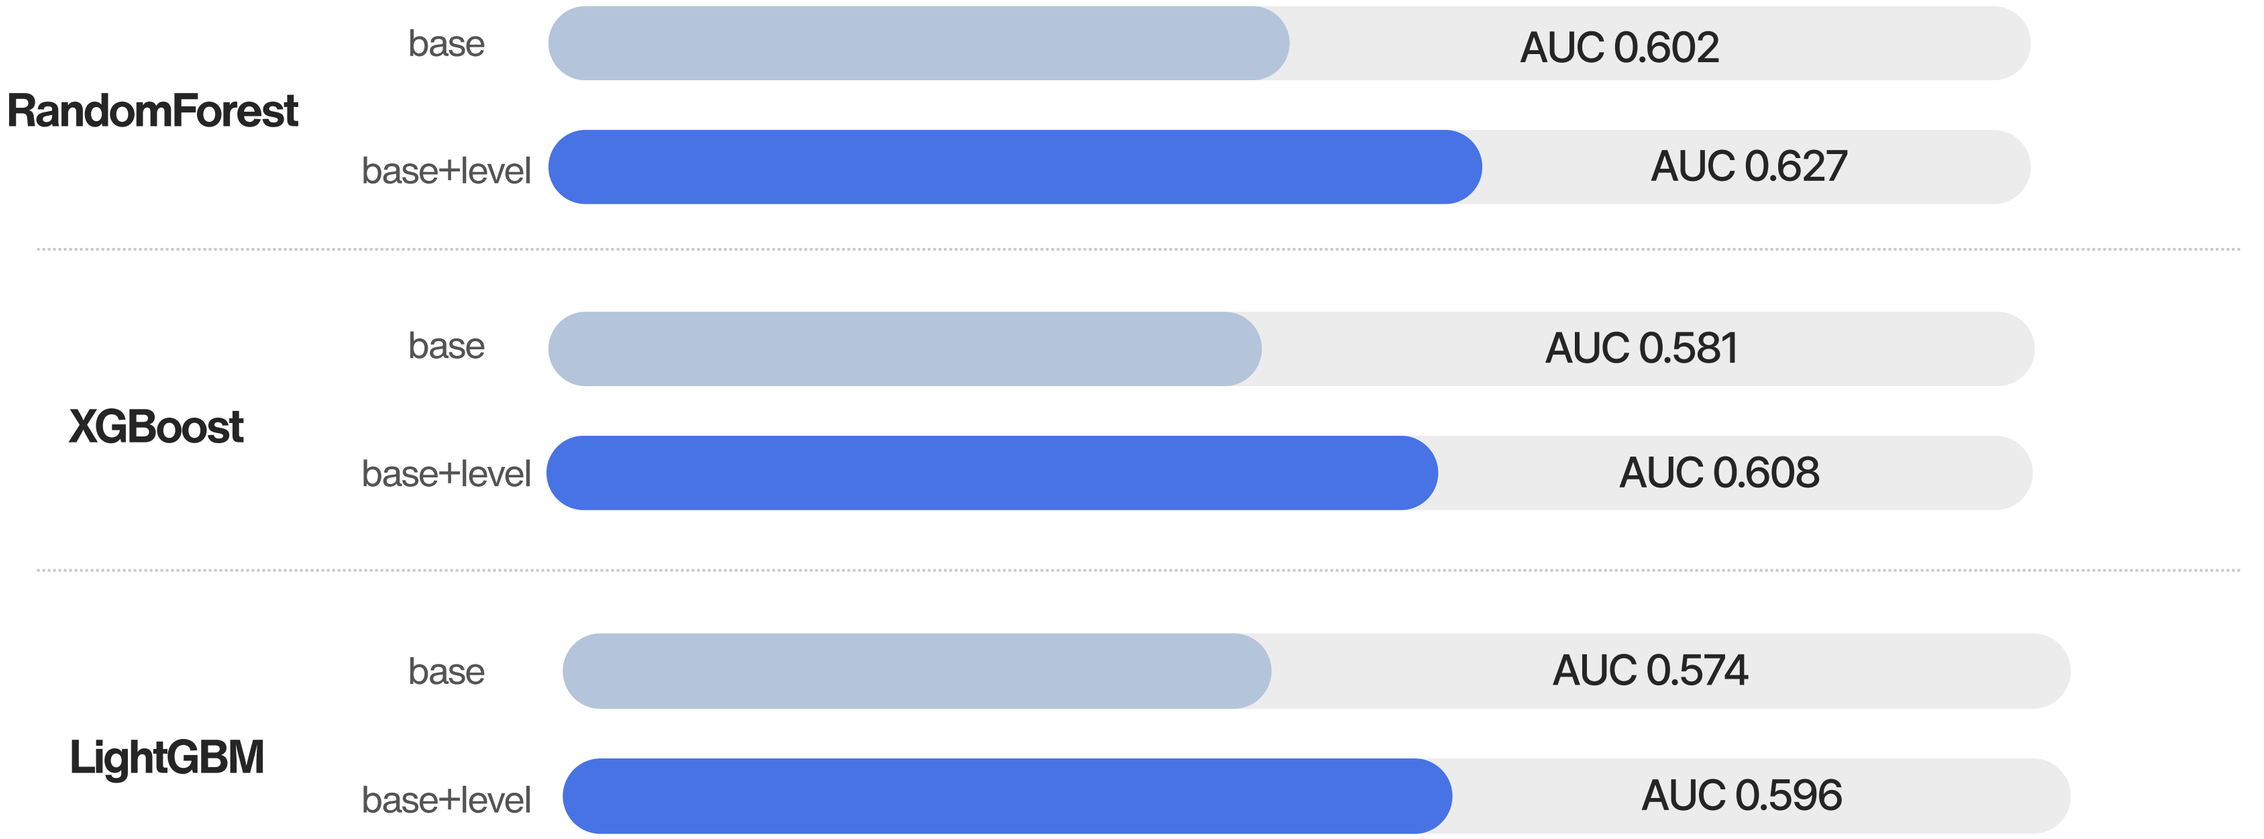
4구간 등급분류 최고 Macro F1

지점당 1~2명

“높음”등급 표본

이용도 등급을 반영한 결제 전환 예측

전환(is_payment) 예측 AUC · base=이용도 등급 미포함, +level=이용도 등급 추가



이용도 등급 추가 후 세 모델의 AUC가 모두 개선됐으며, Random Forest가 AUC 0.627로 가장 높았다.

이용도 등급을 반영한 결제 전환 예측

높음 **35.3%**

보통 **40.6%**



수요없음 **44.1%**



이용도 등급이 높아질수록 결제 전환율은 낮아지는 경향이 나타났다.

개선 작업 A 가설 검증

이용도 등급과 재방문 가설 검증

“이용도 등급과 재방문 포기의 관계는 뚜렷하지 않았다”

경계선 — 통계적 유의하지 않다

등급별 재방문 포기율 차이를
카이제곱 검정으로 확인

P = 0.0545

“재방문을 포기한 사람은 결제 전환율이 낮다”

확인됨 — 뚜렷한 차이

재방문 포기 여부별 결제 전환율 비교

33.9% 포기군 **VS** **45.4%** 재방문군

등급별 재방문 포기율 차이는 통계적으로 유의하지 않았지만, 재방문군의 전환율은 포기군보다 11.5%p 높게 나타났다.

개선 작업 B 성능 개선 시도

결제 전환 모델의 성능 개선 과정

새 변수 추가

가입 경과일 ·다지점 이용 여부 확인

base
0.627

+lag_days
0.631

+multi_site
0.626

+dropout
0.641

AUC 0.627 → 0.641

하이퍼파라미터 튜닝

RandomizedSearchCV 20회 탐색

XGBoost

0.608
튜닝 전

0.613
튜닝 후

AUC 0.608 → 0.613

다른 모델군 비교

6개 모델(로지스틱·SVM·MLP 등)

RandomForest
0.627

신경망
0.616

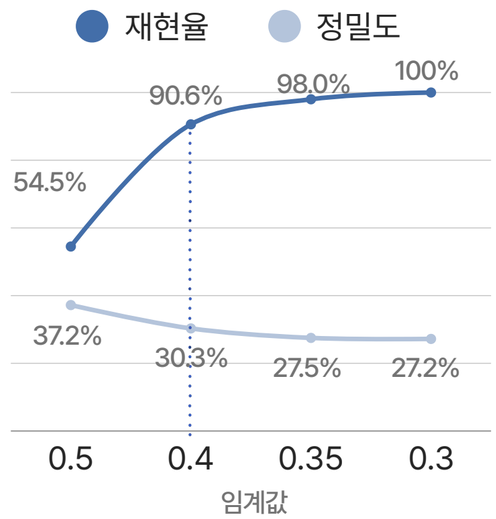
로지스틱회귀
0.615

SVM
0.613

AUC 0.585 ~ 0.627

임계값 조정

0.5 > 0.4 임계값 조정

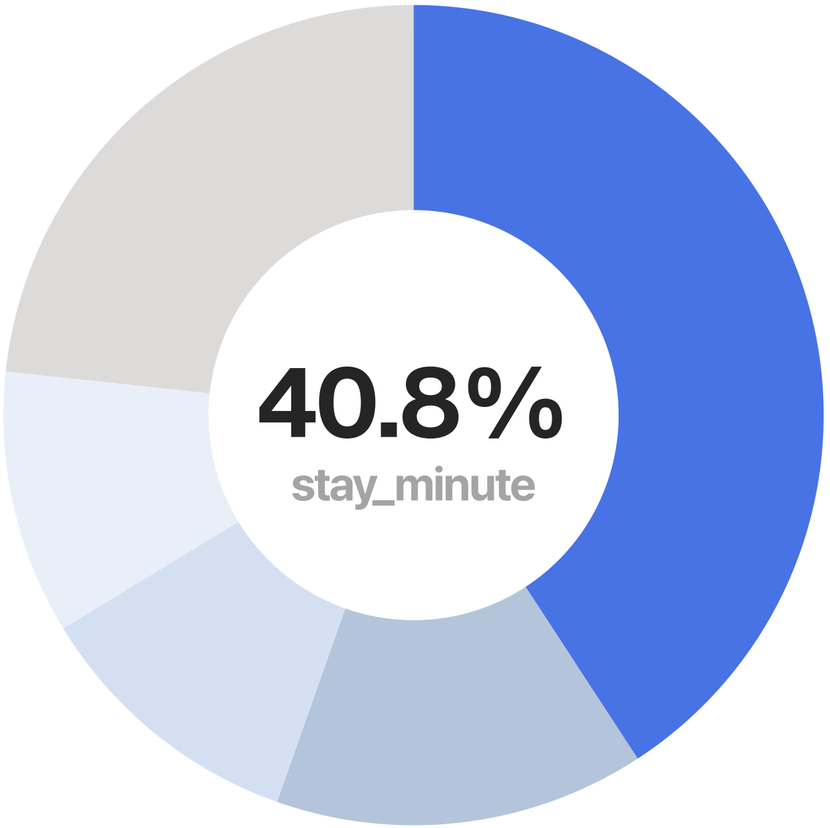


재현율 54.5% > 90.6%
정밀도 37.2% > 30.3%

여러 개선 시도 중 재방문 여부 추가가 가장 큰 성능 개선으로 이어졌다.

dropout을 포함한 Random Forest의 변수 중요도 확인

결제 전환 예측의 핵심 변수 : 체류시간



stay_minute	40.8%
dropout	14.6%
weekday_num	10.9%
site_id	10.4%
그외(time_group_idx,level_idx 등)	23.3%

“dropout(재방문 여부)의 중요도는 14.6%”

dropout 추가는 성능을 개선했지만, 체류시간의 변수 중요도가 높은 비중 차지

최종 모델 선택

이용 행동 변화를 반영한 최종 모델 선정

체류시간 변화량(stay_growth) = 마지막 방문 체류시간 – 첫 방문 체류시간 (1회 방문자는 비교 대상이 없어 0분으로 처리)

평가 지표	예측 성능 최고 모델 base + level + droppout	행동 변화 분석 모델 base + level + droppout +stay_growh
AUC	0.6404	0.6371
Macro F1	0.5800	0.5793
Balanced Accuracy	0.6003	0.5956
재현율	54.5%	52.0%
정밀도	37.2%	37.1%

선정 이유

예측 성능은 기존 모델이 근소하게 높았지만, 재방문 과정의 체류시간 변화를 함께 해석하기 위해 stay_growth 모델을 분석 모델로 활용했다.

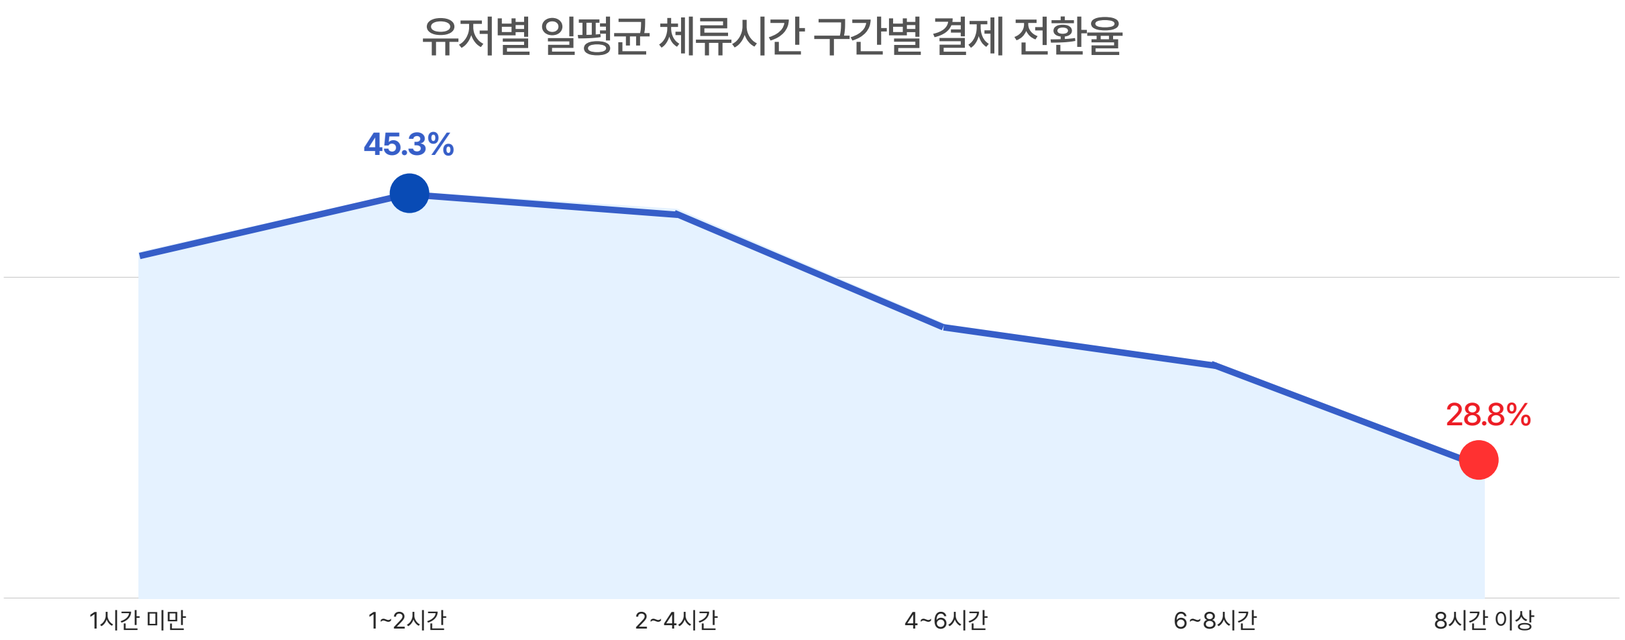
SECTION 06

Key Insights & Action Plan

핵심 인사이트 & 실행 전략

핵심 인사이트 ① 체류시간별 결제 전환율

체류시간 기반 운영 개선



stay_minute

40.8%

모델링 feature importance

운영 제안

체류 4시간 경과 시 멤버십·혜택 안내 메시지 발송
1~2시간 집중 체험 또는 빠른 투어형 프로그램 제공
효과가 확인되지 않으면 체류시간 상한 추가 검토

핵심 인사이트 ② 시간대별 결제전환율

시간대 기반 운영 전략

시간대별 결제 전환율

시간대	전환율	전체 방문 건수(세션) 비중
저녁 (18~24시)	**54.7%**	**15.9%**
심야 (00~06시)	45.7%	1.8%
오전 (06~12시)	41.1%	30.0%
오후 (12~18시)	39.1%	**52.3%**

54.7%

저녁 시간대 전환율

52.3%

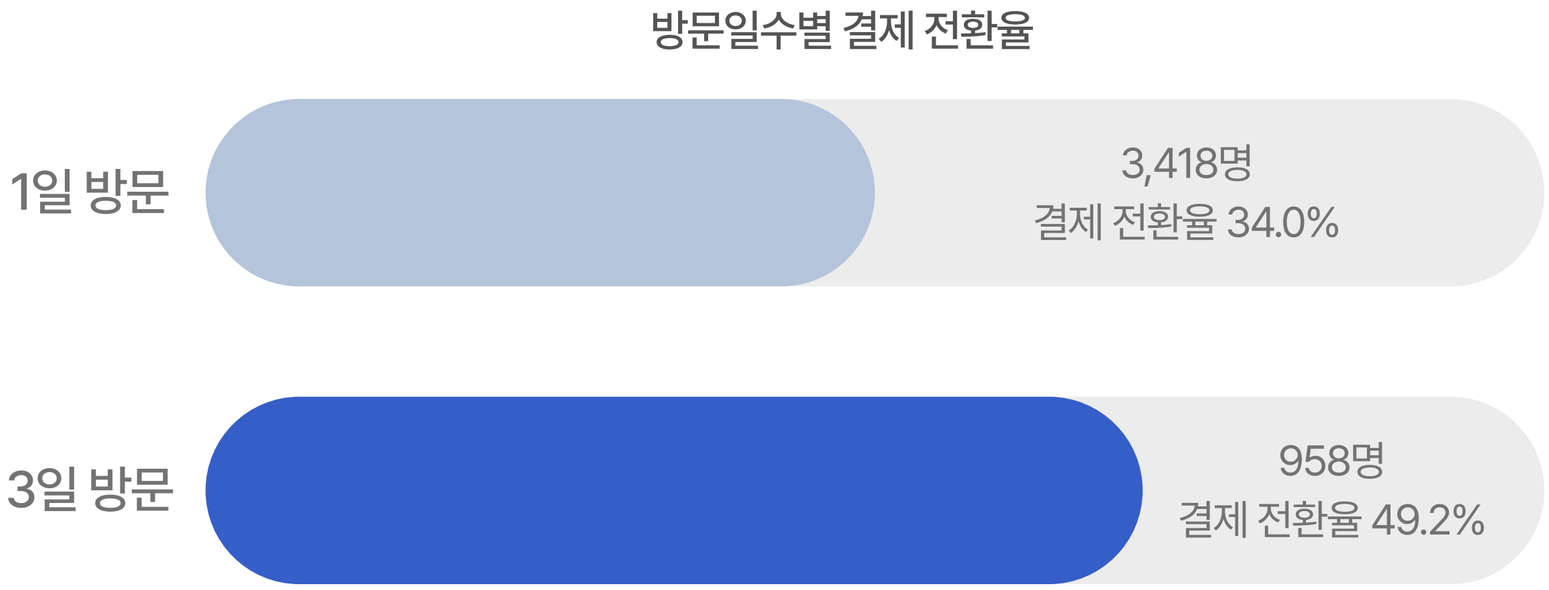
오후 시간대 이용자 비중

운영 제안

저녁 시간대 추천 노출군·비노출군 A/B 테스트
오후 방문자에게 체험 종료 후 재방문·멤버십 안내 발송
오후 피크 시간대에 예약제·시간대별 신청 인원 조정을 시범 적용

핵심 인사이트 ③ 방문일수별 결제 전환율

재방문 유도 및 무료체험 설계



34.2%

신청 후 미방문

1.63일

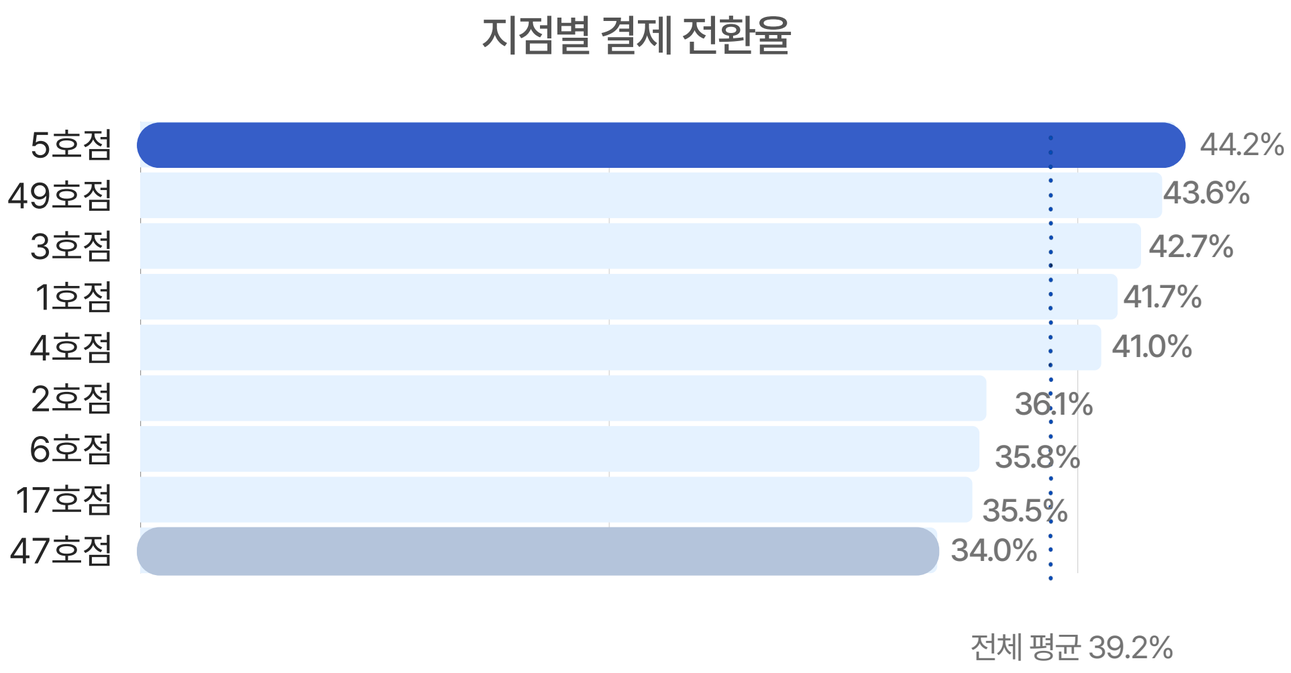
평균 방문 일수

운영 제안

일정 기간 내 원하는 3일을 선택하는 방식으로 유연화
첫 방문 후 남은 체험 횟수와 다음 방문 가능일 안내
미방문자는 24시간 이내 방문 일정 선택 안내
2일 이상 방문 고객 대상 전환 혜택 시범 제공
기존 3일 방식과 2일·선택형 체험의 A/B 테스트

핵심 인사이트 ④ 지점별 결제 전환율

지점 운영 전략



왜 지점 품질 차이로 단정하기 어려운가?

지점별 전환율은 34~44%로 차이가 있으나,
운영기간·이용자 구성·체류시간의 영향이 있어
지점 품질 차이로 단정하기 어렵다

운영 제안

신규 지점은 초기 변동성을 고려해 별도 관리 지표 적용
네트워크형 체험을 시범 운영하고 단일 지점 체험군과 효과 비교
지점별 체류시간 및 이용도를 모니터링해 운영 환경 균질화
저전환 지점은 이용자 구성과 체험 환경을 추가 점검

SECTION 07

Limitations

한계

분석 한계점 도출

01 분석 대상의 제한

신청자 9,624명 중 3,289명(34.2%)이
미방문했으며, 방문 행동 기반 모델에는
이들의 특성이 충분히 반영되지 못함

02 전체 이용도 측정 한계

유료회원 출입 데이터가 없어
무료체험 이용자만으로
산출한 수요가 공간 전체 혼잡도를 반영하지 못함

03 결제 시점 데이터 부재

결제 시각이 없어 체류시간·재방문이
결제 이전 행동인지 결제 이후 행동인지
구분하기 어려움

04 운영 환경 변화 미반영

지점 오픈 시점, 프로모션, 가격·정책 변경 등
운영 요인을 통제하지 못함

05 이용도 등급 매칭의 근사치

첫 방문 날짜와 최빈 지점·시간대로 등급을
매칭해 실제 방문별 수요 경험과
차이가 발생할 수 있음

06 모델 일반화 성능의 제한

Train 41.2%, Test 27.2%로 기간 간 전환율 차이가 크고,
과거 데이터에 의존해 미래 환경에서
성능이 유지된다고 보장하기 어려움.
최종 AUC 약 0.64로 개인별 결제 판단보다
운영 참고용으로 활용하는 것이 적절함

경청해 주셔서
감사합니다!

클래스불균형 곽수연 김채현 박고은 송용진 신예원