공유오피스 무료체험 운영 최적화를 위한 수요 및 결제 전환 예측 분석

중급 **2** 프로젝트

[클래스 불균형팀**]**

곽수연 김채현 박고은 송용진 신예원

목차

I. 서론 **1**
1. 프로젝트 배경 **1**
1-1. 분석 배경 **1**
1-2. 문제 정의 **1**
1) 무료체험 수요는 언제·어디에 집중되는가**?** **1**
2) 무료체험 이용행태는 결제 전환과 어떤 관계가 있는가**?** **1**
3) 무료체험 운영 정책을 어떻게 개선해야 전환율을 높일 수 있는가**?** **2**
2. 분석 목적 **2**
1) 무료체험 수요를 예측하여 운영 효율성을 높인다 **2**
2) 결제 전환을 설명하는 핵심 요인을 규명한다 **2**
3) 분석 결과를 토대로**,** 무료체험 운영 정책을 개선하고 전환율을 높이는 전략을 제시한다 **2**
II. 본론 **2**
1. 데이터 소개 **2**
1-1. 사용 데이터 **2**
1-2. 분석 기간 **4**
1-3. 분석 대상 **5**
2. 전처리 과정 **5**
2-1. 단위 변환 **5**
2-2. 중복치 제거 **6**
2-3. 이상치 제거 **6**
2-3-1.Access ,Visit 테이블 이상치 제거**(**마스터 테이블 생성 전**)** **6**
2-3-2. 자정 로그 이상치 처리**(**마스터 테이블 생성 후 추가 전처리**)** **7**
2-4. 결측치 처리 **8**
2-5. 마스터 테이블 생성 **8**
2-6. 용어 정의 **11**
3. 무료 체험 이용 패턴 분석 **(EDA)** **11**
3-1. 시간대별 이용 패턴 및 결제 전환율 **11**
3-2. 요일별 이용 패턴 및 결제 전환율 **12**
3-3. 지점별 이용 패턴 및 결제 전환율 **14**
3-4. 체류시간 분포 **17**
3-5. 방문일수 및 재방문 패턴 **19**
4. 1차 모델링 **-** 무료체험 수요 예측 **20**
4-1. 배경 및 전체 흐름 **20**
4-2. 1시간 단위 연속값 회귀 예측 **20**
4-3. 4구간**(**오전**/**오후**/**저녁**/**심야**)** 단위 회귀 예측 **21**
4-4. 요일 단위 회귀 예측 **22**
4-5. 1시간 단위 등급 분류 전환 **24**
4-6. 4구간 단위 등급 분류 전환 **- 1**차 최종 모델 **25**

4-7. 한계점 및 **2**차 모델링 필요성 **27**
5. 2차 모델링 **-** 결제 전환 예측 **27**
5-1. 배경 및 전체 흐름 **27**
5-2. 데이터 준비 **27**
5-3. Train/Test 분리 **28**
5-4. Base Model - 기본 행동 변수 기반 전환 예측 **28**
5-5. Base + Level - 이용도 추가 **29**
5-6. Base + Level + Dropout - 재방문 여부 추가 **30**
5-7. Base + Level + Dropout + Stay_growth - 체류시간 변동성 추가 **32**
6. 모델 최종 선택 **33**
III. 결론 **35**
1. 분석 결과 요약 **35**
2. 제안 및 기대효과 **35**
3. 한계점 **39**
부록 **42**
2차 모델링 **42**
1. 관계 구조 탐색 **–** 첫 방문 이용도**,** 재방문 여부와 결제 전환 **42**
2. 추가 개선 시도 **43**

요약

본 분석은 2021년 5월~2023년 12월 공유오피스 무료체험 이용객의 신청·방문·출입·결제·지점 데이터(총 6,335명)를 활용해 시간대별 동시 체류 수요를 예측하고, 체류시간 및 재방문 등 주요 이용행태가 유료 멤버십 결제 전환에 미치는 영향을 분석하였다.

분석 결과, 무료체험 이용은 주중 오후(52.3%)에 이용이 집중되었으나, 해당 시간대의 실질적인 결제 전환율은 39.1%로 낮았고, 반대로 저녁 시간대(15.9%)는 54.7%로 가장 높았다. 체류시간은 길수록 결제 전환에 유리하기보다는 30분~2시간 구간에서 전환율이 가장 높고(약 53%), 일평균 8시간 이상 이용 시 전환율이 28.8%까지 하락하는 비선형 관계가 확인되었다. 방문일수 증가와 재방문 여부는 전환율을 높였으나, 첫 방문의 수요등급이 재방문 포기와 직접적으로 연결되지는 않았다.

수요 예측 모델은 1시간 단위에서는 0명 비중이 높아 한계가 있었고, 4구간 확장 후 R^2가 0.30 수준으로 개선, Random Forest 분류 모델의 Macro F1은 0.544로 나타났다. 결제 전환 예측에서는 체류시간(중요도 40.8%)과 재방문 여부(14.6%)가 핵심 변수였으며, 수요등급 추가 시 AUC가 0.602 → 0.627 → 0.640으로 소폭 상승했다. 다만 모델은 개인 결제 여부를 정밀 예측하기보다는 운영 전략을 보조하는 탐색적 도구로 활용하는 것이 적절할 것으로 판단하였다.

운영 측면에서는 장시간 이용 유도보다 적정 체류시간 탐색, 첫 방문 후 리마인더 기반 재방문 유도, 오후 시간대의 예약 분산 및 전환 안내, 저녁 시간대 추천 운영 등이 제안되었다. 또한 지점별 전환율 차이는 운영기간·이용자 구성·체류시간을 함께 고려하여 해석해야 한다. 결제 시점 및 유료 회원 데이터가 없어 인과관계 확정은 어려우므로, A/B테스트를 통한 검증이 필요하다.

I. 서론

1. 프로젝트 배경

1-1. 분석 배경

공유오피스의 무료체험은 잠재 고객이 실제 업무 공간과 서비스를 경험하고 유료 멤버십 가입 여부를 판단하는 주요 단계이다. 따라서 무료체험은 단순한 무상 이용을 넘어 고객의 첫 이용 경험을 결제 전환으로 연결하는 중요한 과정이라 할 수 있다.

그러나 무료체험 이용자는 모두 같은 방식으로 공간을 이용하지 않는다. 이용 지점과 방문 시간대, 체류시간, 방문일수 및 재방문 여부에 따라 체험 방식이 달라지며, 이러한 이용행태는 결제 전환과도 관련될 가능성이 있다. 또한 특정 지점이나 시간대에 무료체험 수요가 집중되면 공간 이용에 불편이 발생하는 반면, 수요가 낮은 시간에는 체험 공간이 비효율적으로 운영되는 문제가 나타난다.

효율적인 무료체험 운영을 위해서는 신청자 수와 전체 결제 전환율만 확인하는 데서 벗어나, 이용자가 언제·어디에서·얼마나·몇 번 공간을 이용했는지 구체적으로 파악해야 한다. 나아가 결제 전환과 관련된 주요 이용 특성을 확인함으로써 체험 운영과 전환 전략을 설계할 수 있는 근거를 마련할 필요가 있다.

이에 본 프로젝트에서는 약 1만 건의 무료체험 이용 로그와 9천여 건의 신청 데이터를 활용하여 지점·요일·시간대별 수요 패턴과 결제 전환에 관련된 이용 특성을 분석한다. 또한 과거 이용 패턴을 설명하는 데 그치지 않고, 요일·시간대별 동시 체류 수요와 이용자의 결제 전환을 예측하는 모델을 구축하여 무료체험 운영 전략을 마련할 수 있는 데이터 기반 근거를 제시하고자 한다.

1-2. 문제 정의

무료체험 운영을 개선하기 위해서는 다음과 같은 근본적인 질문들에 답해야 한다.

1) 무료체험 수요는 언제·어디에 집중되는가**?**

공유오피스 운영팀은 시간대별·요일별·지점별 무료체험 인원이 동시에 어느 정도 머무르고 있는지를 사전에 파악해야 좌석·공간·인력 운영을 효율적으로 배치할 수 있다. 즉, 단순히 “하루에 몇 명이 왔는가”가 아닌 “특정 시점에 실제로 해당 공간에 존재하는 동시 체류 인원이 몇 명인지 혹은 어느 수준인지”를 파악할 필요가 있다.

2) 무료체험 이용행태는 결제 전환과 어떤 관계가 있는가**?**

예를 들어, 체류시간이 길수록 전환율이 높아지는지, 혹은 짧게 여러 번 방문하는 것이 더 효과적인지, 공유오피스 이용자가 많은 시간대에 체험한 고객이 실제로 결제를 덜 하는지 등은 운영 정책을 설계하는 데 중요한 질문이다. 이에 따라,

방문시간대·체류시간·방문일수·재방문 여부 등의 이용행태 정보가 최종적으로 “결제로 이어졌는지”를 통계적으로 검증해볼 필요가 있다.

3) 무료체험 운영 정책을 어떻게 개선해야 전환율을 높일 수 있는가**?**

무료체험 기간을 3일로 제공하는 것이 적절한지, 특정 시간대를 추천해야 하는지, 재방문을 유도하는 것이 실제로 전환율을 높이는지 등 결제 전환과 관련된 주요 이용 특성을 위 분석을 통해 검증하여, 무료체험 운영 및 전환 전략에 활용할 수 있는 근거를 마련하고자 한다.

2. 분석 목적

따라서 본 분석의 목적은 크게 다음의 세 가지이다.

1) 무료체험 수요를 예측하여 운영 효율성을 높인다**.**

요일·시간대별 동시 체류 인원을 예측함으로써 운영팀이 공유오피스에 고객이 몰리는 정도를 사전에 파악하고 공간·좌석·인력 배치를 최적화할 수 있도록 한다.

2) 결제 전환을 설명하는 핵심 요인을 규명한다**.**

체류시간, 방문일수, 재방문 여부, 이용이 몰리는 정도 등 다양한 이용행태가 결제 전환과 어떤 관계가 있는지 분석하여, 전환율을 높이는 데 기여하는 요인을 명확히 파악한다.

3) 분석 결과를 토대로**,** 무료체험 운영 정책을 개선하고 전환율을 높이는 전략을 제시한다**.**

체험 시간 구성, 시간대 추천, 재방문 유도, 무료체험 기간 조정 등 운영팀이 즉시 적용할 수 있는 개선안을 도출하는 것을 최종 목표로 한다.

II. 본론

1. 데이터 소개

본 분석은 trial_register, trial_visit_info, trial_access_log, trial_payment, site_area의 총 5가지 데이터를 기반으로 수행되었다. 데이터에는 무료체험 신청 정보, 입·퇴실 로그, 출입 기록, 결제 여부, 지점 면적 등이 포함되어 있으며, 이를 결합하여 이용자의 실제 체험 행동을 정교하게 재구성하였다.

1-1. 사용 데이터

다음은 사용된 원본 데이터의 명세서이다.

(1) trial_register (9,659 행)

[표 II-1] 무료체험 신청자 정보

컬럼명	타입	설명
user_uuid	문자열 (object)	유저 고유 id
time_date	문자열 (object)	3일 체험 신청 시각

(2) trail_visit_info (11,477 행)

[표 II-2] 방문자 정보

컬럼명	타입	설명
site_id	정수형 (int)	공유 오피스 지점 id
date	문자열 (object)	이용날짜 (KST)
stay_time	문자열 (object)	재실시간
stay_time_second	정수형 (int)	재실시간 초 단위
first_enter_time	문자열 (object)	해당일자 첫 입실 시각 (KST)
last_leave_time	문자열 (object)	해당일지 마지막 퇴실 시각 (KST)
user_uuid	문자열 (object)	유저 고유 id

(3) trial_access_log (63,708 행)

[표 II-3] 입/퇴실 정보

컬럼명	타입	설명
checkin	정수형 (int)	입실 : 1 퇴실 : 2
cdate	문자열 (object)	출입 로그 생성 시각
site_id	정수형 (int)	공유 오피스 지점 id
user_uuid	문자열 (object)	유저 고유 id

(4) trial_payment (9,659 행)

[표 II-4] 결제 정보

컬럼명	타입	설명
is_payment	정수형 (int)	결제시 : 1 미결제시 : 0
user_uuid	문자열 (object)	유저 고유 id

(5) site_area (9 행)

[표 II-5] 지점 정보

컬럼명	타입	설명
site_id	정수형 (int)	공유 오피스 지점 id
area_pyeong	정수형 (int)	지점 면적

1-2. 분석 기간

본 분석은 2021-05-02부터 2023-12-31까지 약 2년 8개월간의 무료체험 데이터를 대상으로 수행하였다. 원본 데이터는 2024-01-02까지 존재하였으나, 2024년 1월 데이터는 총 14행으로 표본이 지나치게 적었다. 모델링 학습 단계에서 해당 연도의 극히 적은 데이터로 인한 왜곡을 방지하고 분석의 일관성을 유지하기 위해 본 분석에서는 2024년 1월 데이터를 제외한 2021-05-02 ~ 2023-12-31 기간만을 사용하였다.

1-3. 분석 대상

본 분석에서는 크게 두 가지의 서로 다른 분석 대상을 설정하였다.

1) **1**차 분석

공유오피스 무료체험 이용자들의 지점별·요일별·시간대별 수요 패턴을 파악하여 무료체험이 실제로 언제, 어디에서, 얼마나 이용되는지를 정량적으로 확인한다.

2) **2**차 분석

1차 분석 결과의 연장선에서, 무료체험 이용자들의 결제 전환에 영향을 미치는 주요 이용행태 요인을 규명한다. 체류시간, 방문일수, 재방문 여부, 이용도 등 다양한 행동 변수가 결제 전환과 어떤 관계를 갖는지 분석하여 무료체험 운영 정책 개선에 활용할 수 있는 실질적 근거를 마련한다.

2. 전처리 과정

이번 프로젝트에서는 데이터 신뢰도 확보가 핵심이라고 판단하였기에, 모델링 이전에 상당한 전처리 및 세션 복원 작업을 수행하였다. 무료체험 데이터는 입·퇴실 로그가 여러 형태로 분절되어 있거나, 시스템적 오류로 인해 비정상적인 체류시간이 기록된 경우가 존재할 가능성이 높기 때문에, 실제 이용 패턴을 최대한 정확히 복원하는 작업이 필수적이었다.

2-1. 단위 변환

다음과 같이 날짜 관련 컬럼의 단위를 KST로 통일하였다.

[표 **II-6]** 단위 변환

테이블	컬럼	기본 타입	변환 후 타입
trial_access_log	cdate	문자열 (object)	datetime (KST)
trial_register	trial_date		datetime(KST)
trial_visit_info	date		datetime (KST)
	first_enter_time		datetime (KST)
	last_leave_time		datetime (KST)
	stay_time		timedelta

2-2. 중복치 제거

전체 행을 기준으로 다음과 같이 중복값을 제거하였다.

[표 II-7] 중복치 제거

테이블	중복 유형	개수	처리 방법
trial_access_log	완전 중복 행	359행	drop_duplicates()
trial_payment		35행	
trial_register		28행	
trial_visit_info		48행	

2-3. 이상치 제거

2-3-1. `Access` ,`Visit` 테이블 이상치 제거(마스터 테이블 생성 전)

[표 II-8] 이상치 제거

테이블	이상치 기준	이상치 개수	처리 방법
trial_visit_info	stay_time_second < 60초	26행	제거
trial_access_log	최초 입실 시간 > 마지막 퇴실 시간	41행	제거

Visit 테이블 이상치 처리

Visit 테이블에서는 stay_time_second 기준으로 1분(60초) 미만인 기록을 이상치로 판단하였다. 전체 데이터를 확인한 결과 해당 조건에 해당하는 기록은 26행이었으며, 음수 값은 존재하지 않았다.

해당 26행은 공유오피스 이용 목적을 위한 실질적인 방문으로 보기 어려워 이상치로 간주하고 제거하였다. 제거 후 재검증을 진행한 결과, stay_time_second가 1분 미만인 기록과 last_leave _time - first_enter_time이 60초 미만인 기록, 그리고 퇴실 시각이 입실 시각보다 빠른(역전된) 기록이 모두 0행으로 확인되어, 데이터가 정상적으로 정제되었음을 확인하였다.

Access 테이블 이상치 처리

퇴실 시각에서 입실 시각을 뺀 이용시간(duration_minutes)이 1분 미만인 이상치는 45행이었으며, 이 중 22행은 음수 값으로 나타났다.

음수 값이 발생한 22행을 유저별 로그와 대조하여 개별 검토한 결과, 4행은 밤 10~11시경 입실 후 자정을 넘겨 다음 날 퇴실이 기록되면서 날짜 기준 계산상 음수로 나타난 것일 뿐 실제로는 정상적인 이용 기록으로 확인되어 유지하였다. 나머지 18행은 입실 또는 퇴실 중 한쪽 기록이 누락된 경우 등으로, 정상적인 이용으로 보기 어려워 이상치로 판단하고 제거하였다.

최종적으로 1분 미만(비음수) 이상치 23행과 음수 이상치 18행, 총 41행을 제거하여 9,119행이었던 access 요약 데이터는 9,078행으로 정제되었다.

2-3-2. 자정 로그 이상치 처리**(**마스터 테이블 생성 후 추가 전처리**)**

마스터 테이블 11,317행 중 00:00:00 입실 738행, 23:59:59 퇴실 727행이 발견되었다. 그 중 입실 퇴실 둘 다 해당하는 행은 114행으로 총 1,351행이 자정 입실과 퇴실 이상치로 추측되었다. 이는 하루 단위로 방문 기록을 나누는 시스템 특성상, 자정을 넘겨 이용한 세션이 전날과 다음날 두 개의 행으로 쪼개지면서 생긴 현상이다. 해당 이상치로 추측되는 1,351행은 다음과 같이 세 그룹으로 분류되었다.

[표 **II-9]** 자정 로그 이상치 처리

그룹	내용	처리 전 행 수	처리 방법
그룹 1	1박 정상 밤샘 근무 (복원 대상)	868행	전날/다음 날로 분리된 2행을 1개 방문으로 통합 → 434행
그룹 2	2~3박 장기체류 이상치 (제거 대상)	250행	체크아웃 태그 누락으로 판단하여 전량 삭제
그룹 3	짝 없는 단독 로그 (제거 대상)	233행(137+126)	전후 관계 입증이 불가능하여 전량 삭제

그룹 **1 (**복원**)**: 하루 밤을 넘겨 이용한 정상적인 1박 이용 기록으로, 전날의 입실과 다음날의 퇴실을 하나의 방문으로 합쳐 868행을 434행으로 복원하였다.

그룹 **2 (**삭제**)**: 자정을 2~3회 연속으로 넘겨 48시간 이상 체류한 것으로 기록된 250행이다. 공유오피스 특성상 연속 체류가 비현실적이므로, 퇴실 태그 누락에 의한 센서 오류로

판단하고 전량 삭제하였다.

그룹 **3 (**삭제**)**: 전날의 퇴실 또는 다음날의 입실 짝이 없어 전후 관계를 확인할 수 없는 233행이다. 복원 근거가 없는 파편 데이터로 판단하고 전량 삭제하였다.

한편 짝 없는 행을 단순 산술로 계산하면 263행(00시 입실 137행 + 23:59 퇴실 126행)이지만, 실제 그룹 3은 233행으로 30행의 차이가 있다. 이는 ① 그룹 2(2~3박 이상치)에 포함된 중간 날짜의 자정 기록 25행이 단순 산술에서 중복 집계되었고, ② 앞뒤 날짜 연결 없이 한 행에 00:00:00 입실~23:59:59 퇴실이 동시에 기록된 5건이 00시 입실 목록과 23:59 퇴실 목록 양쪽에 이중 집계되었기 때문이다. 두 항목(25행+5행=30행)을 제외하면 순수한 그룹 3 규모인 233행과 일치한다.

2-4. 결측치 처리

[표 **II-10]** 결측치 처리

테이블	결측 컬럼	결측	처리 방법
trial_visit_info	first_enter_time	555건	access 테이블 기반 보완
	last_leave_time		

user_uuid와 site_id를 기준으로 visit 테이블과 access 테이블을 매핑하고 access 테이블의 cdate를 활용하여 first_enter_time과 last_leave_time의 결측치를 보완하였다.

매핑 후에도 first_enter_time **79**건, last_leave_time **76**건의 결측치가 남았고
access 테이블에 해당 유저의 출입 로그가 없거나, 해당 날짜의 로그가 존재하지 않아 보완이 불가능한 경우로 확인하였다. 결국 두 시간 정보 중 하나만 결측인 경우에도 정확한 재실시간 산정이 어려우므로 해당 행을 제거하기로 결정했다**.**

2-5. 마스터 테이블 생성

이상치 제거 및 세션 복원 등 전처리 작업 전후로 체류시간 왜곡이 크게 개선됨을 확인하였으며, 최종적으로 다음과 같은 2가지의 마스터 테이블을 생성하여 모델링 작업을 진행하였다.

1) 최종 세션 테이블 (10,402행) - 1차 분석용

[표 **II-11]** 최종 세션 테이블

컬럼명	타입	설명
site_id	정수형 (int)	공유오피스 지점 id

date	날짜형 (datetime)	입실 날짜 (연-월-일)
user_uuid	문자열 (object)	유저 고유 id
first_enter_time	날짜형 (datetime)	최초 입실 시각
last_leave_time	날짜형 (datetime)	최후 퇴실 시각
stay_time_second	실수형 (float)	재실시간 초 단위
is_payment	정수형 (int)	결제시 : 1 미결제시 : 0
area_pyeong	정수형 (int)	지점 면적
stay_minute	실수형 (float)	재실시간 분 단위
enter_hour	정수형 (int)	입실 시간대 (시)
leave_hour	정수형 (int)	퇴실 시간대 (시)
weekday	문자열 (object)	요일 (영문)
day_name_kr	문자열 (object)	요일 (국문)

2) 유저별 집계 테이블 (6,337명) - 2차 분석용

결제 전환 예측을 위해 위 최종 세션 테이블을 유저 단위로 집계하였다. 단, 첫 방문 날짜 매칭이 실패한 유저 2명에 대해서는 삭제 후 총 6,335명에 대해 분석을 진행하였다.

[표 II-12] 유저별 집계 테이블

컬럼명	타입	설명
user_uuid	문자열 (object)	유저 고유 id
visit_count	정수형 (int)	무료체험 총 방문 횟수 (최대 3번)
site_id	정수형 (int)	유저가 가장 자주 이용한 주 이용 지점 id
area_pyeong	정수형 (int)	주 이용 지점의 면적
weekday	정수형 (int)	가장 자주 방문한 최빈 요일 라벨링 0: 월 1: 화 2: 수 3: 목 4: 금

		5: 토 6: 일
weekday_num	정수형 (int)	weekday와 동일한 요일 번호 (하위 호환용 컬럼)
weekend_ratio	실수형 (float)	총 방문 횟수 중 주말 방문 비율
is_weekend	정수형 (int)	최빈 방문 요일이 주말인지 여부 0: 평일 1: 토/일
time_group	문자열 (object)	가장 자주 입실한 최빈 시간대 그룹 (국문) 야간: 0-6시 오전: 6-12시 오후: 12-18시 저녁: 18-24
time_group_idx	정수형 (int)	최대 시간대 그룹 라벨링 0: 야간 1: 오전 2: 오후 3: 저녁
time_slot_idx	정수형 (int)	time_group_idx와 동일한 시간대 인덱스 (하위 호환용 컬럼)
stay_minute	정수형 (int)	유저의 1회 방문당 체류 시간 중앙값
is_payment	정수형 (int)	무료체험 후 최종 유료 결제 전환 여부 0: 미결제 1: 유료결제 전환
date	날짜형 (datetime)	유저의 최초 방문 일자
dropout	정수형 (int)	재방문 포기/이탈 여부 플래그
level	문자열 (object)	유저가 첫 방문한 시점의 공유오피스 이용도 등급: ‘수요 없음’ ‘보통’ ‘높음’
level_idx	정수형 (int)	level 컬럼 등급 라벨링 0: 수요 없음 1: 보통 2: 높음

stay_growth	정수형 (int)	첫 방문 대비 마지막 방문의 체류시간 변화량 (마지막 방문 stay_minute − 첫 방문 stay_minute)

2-6. 용어 정의

본 분석에서는 공유오피스에 무료체험 이용객들이 몰리는 정도를 '이용도'라고 표현하였다.

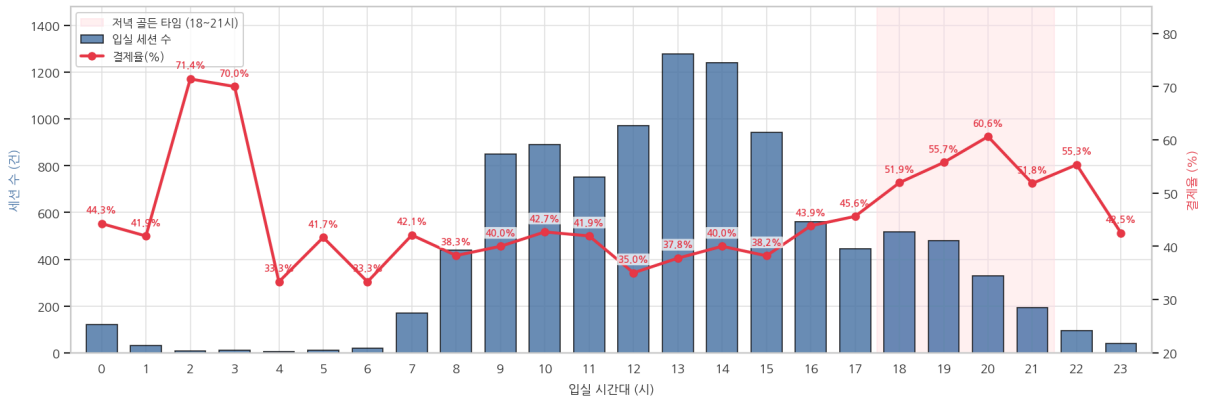
3. 무료 체험 이용 패턴 분석 **(EDA)**

무료체험 데이터의 기본적인 이용 패턴을 파악하기 위해 지점별·요일별·시간대별 수요, 체류시간 분포, 방문일수, 전환율 차이 등을 다각도로 분석하였다. 이를 통해 무료체험 운영 현황을 정량적으로 이해하고, 이후 모델링 및 전환 분석에서 고려해야 할 주요 변수를 식별할 수 있었다.

3-1. 시간대별 이용 패턴 및 결제 전환율

무료체험 이용은 시간대별로 매우 뚜렷한 편중을 보였다.

[그림 **II-1]** 시간대별 입실 건수 및 결제 전환율 추이



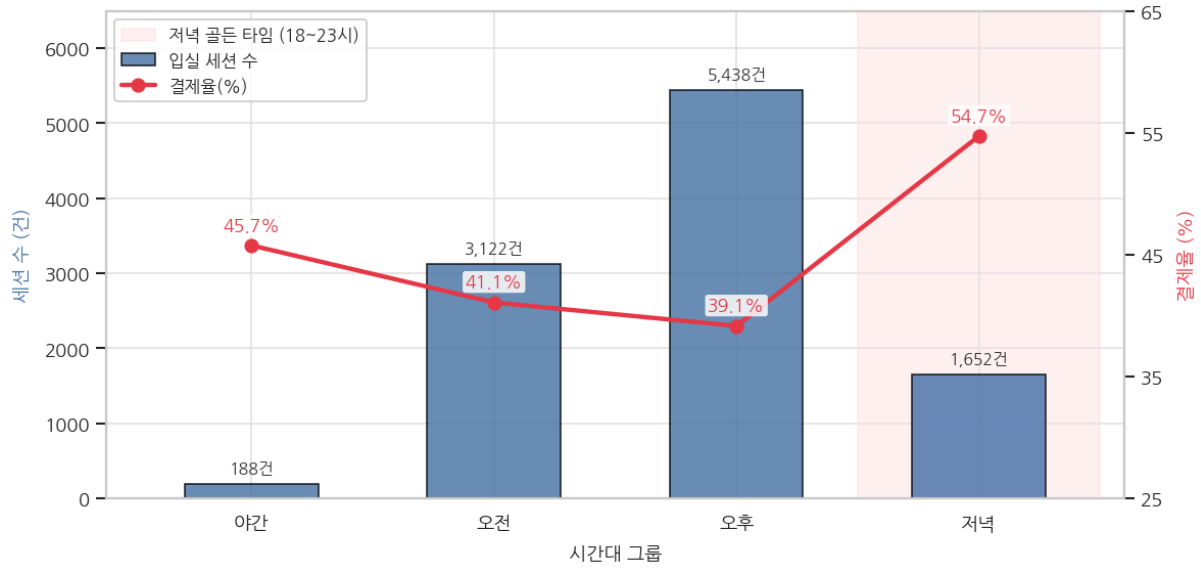
다음 그래프는 전체 시간대별 입실 방문 건수와 결제 전환율을 같이 나타내고 있다. 오후 시간대 13시에 가장 많은 방문자 수를 확인했다. 16시부터 방문 건수가 급감하고 있으며 야간 시간대에는 방문 건수가 0에 가까운 것을 확인했다. 하지만 결제 전환율은 이와 완전히 상반된 결과를 보이고 있다. 방문 건수가 적을수록 결제 전환율이 높게 나타났으며 이를 통해 둘은 강한 음의 관계라는 것을 확인했다.

다음 분석 단계로 전체 시간대를 4개의 구간으로 나누어 고유 이용자 수와 각 나눈 시간대 구간별 결제 전환율을 비교하였다. 시간대는 심야, 오전, 오후, 저녁으로 구간을 나누었다.

[표 II-13] 시간대별**(4**분할**)** 방문량 및 결제 전환율

시간대	방문량 및 비율**(**건**, %)**	고유 이용자 수**(**명**)**	결제 전환율**(%)**
심야(0~5:59)	188건 (1.8%)	163	45.7
오전(6~11:59)	3,122건 (30.0%)	2,252	41.1
오후(12~17:59)	**5,438**건 **(52.3%)**	**4,013**	**39.1**
저녁(18~23:59)	1,654건 (15.9%)	1,368	54.7

[그림 II-2] 시간대별**(4**분할**)** 방문량 및 결제 전환율



일반적인 공유오피스 업무 시간대와 일치하는 '오후' 시간대에 무료체험이 집중되는 구조를 확인하였다. 다만, 오후 시간대는 결제 전환율이 가장 낮은 구간이기도 하여, 단순히 수요가 많은 시간대가 반드시 전환에 유리한 것은 아니라는 점을 시사한다.

3-2. 요일별 이용 패턴 및 결제 전환율

다음은 요일·시간대별 방문량과 결제 전환율을 분석한 결과이다. 요일별로는 수·목·금에 이용이 집중되는 경향이 나타났다.

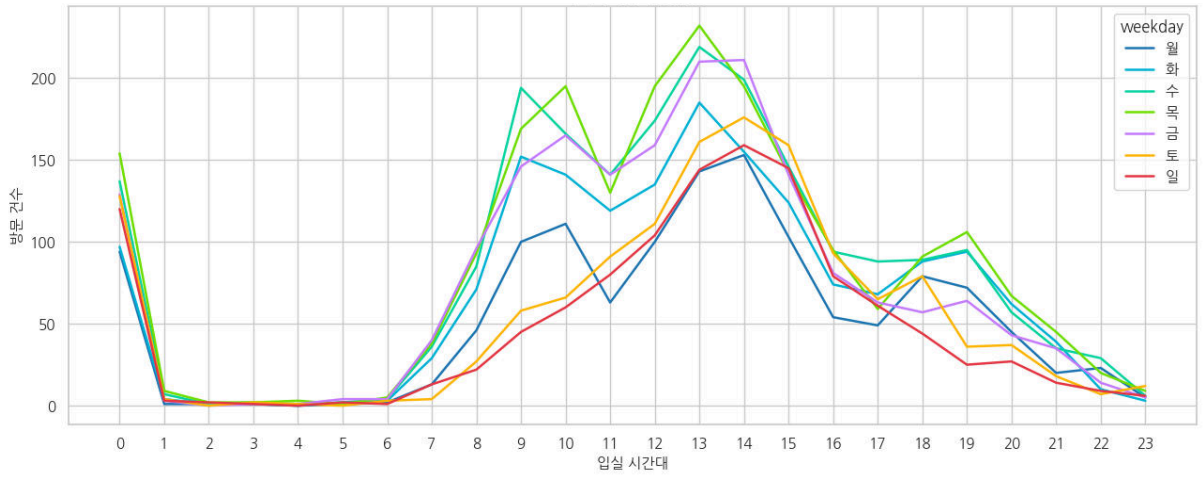
[표 II-14] 요일별 일평균 방문량 및 비율

요일	일평균 방문 건수**(**건**)**	비율**(%)**

월	9.1	주중 **77.8% (63.4**건**)**
화	11.9	
수	**14.4**	
목	**15.0**	
금	**13.0**	
토	9.7	주말 22.2% (18.1건)
일	8.4	

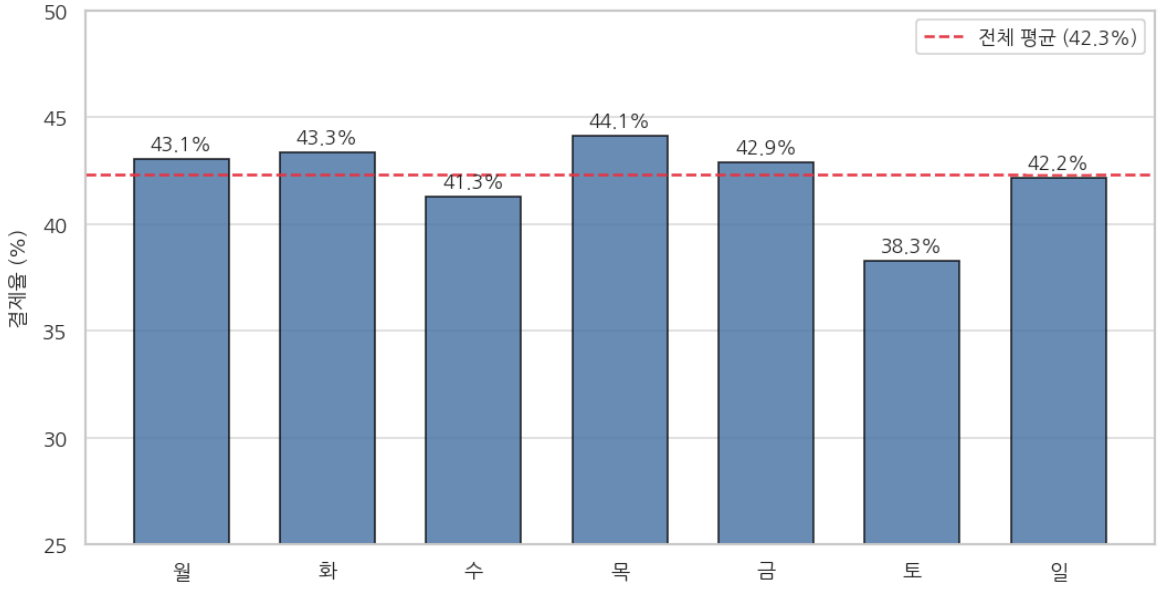
요일별 일평균 방문 건수는 목요일이 15.0건으로 가장 많았으며, 수요일(14.4건)과 금요일(13.0건)이 그 뒤를 이었다. 반면 일요일은 8.4건으로 가장 낮게 나타났다. 전체적으로 주중 방문이 일평균 63.4건으로 전체 방문의 77.8%를 차지해, 주말보다 주중에 이용이 집중되는 패턴을 확인할 수 있었다.

[그림 **II-3]** 요일 및 시간대별 방문량



시간대별로는 평일의 경우 12~15시를 중심으로 방문량이 크게 증가하며 높은 방문량이 이어지는 패턴이 나타났다. 반면 주말은 평일에 비해 전반적으로 방문량이 낮았으며, 14~15시 전후에 상대적으로 높은 방문량이 나타났다.

[그림 **II-4]** 요일별 결제 전환율



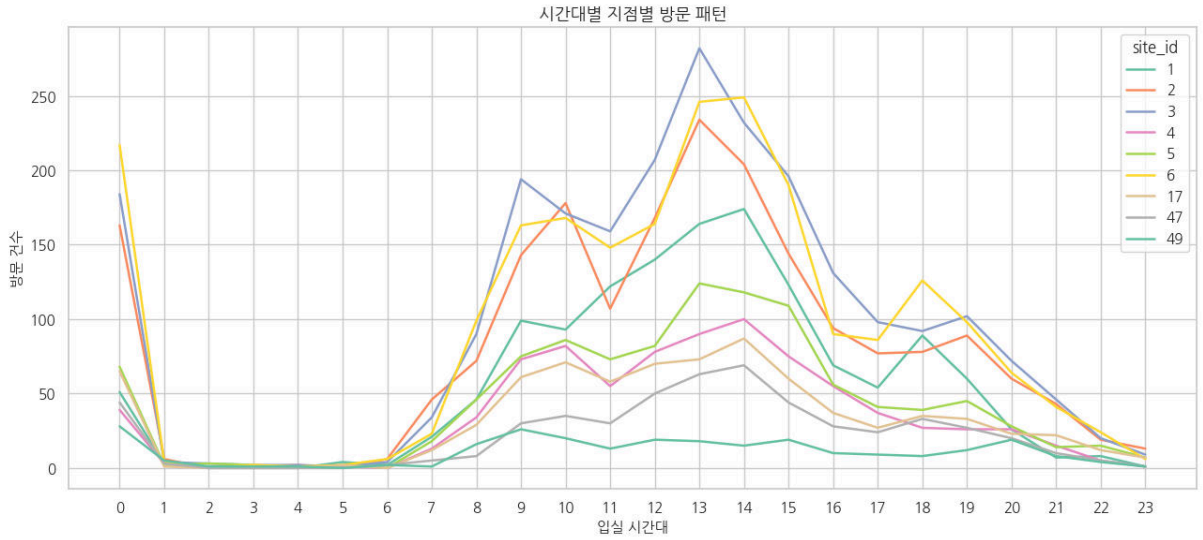
요일별 방문량의 차이가 실제 결제 전환율의 차이로 이어지는지도 확인해본 결과, 목요일의 결제 전환율이 **44.1%**로 가장 높았고, 토요일이 **38.3%**로 가장 낮았으나, 대부분의 요일은 **41~44%** 수준으로 나타났다. 특히 방문량이 많았던 수·목·금의 결제 전환율은 각각 **41.3%**, **44.1%**, **42.9%**로 다른 요일과 큰 차이를 보이지 않았다.

따라서 요일에 따라 이용량에는 차이가 존재하지만, 현재 데이터상으로는 특정 요일의 이용자가 다른 요일에 비해 뚜렷하게 높은 결제 전환율을 보이는 패턴은 확인되지 않았다. 즉, 무료체험 이용은 수·목·금 등 주중 특정 요일에 집중되는 반면, 방문 요일 자체는 결제 전환을 구분하는 주요 요인으로 나타나지 않음을 확인하였다.

3-3. 지점별 이용 패턴 및 결제 전환율

다음으로 지점별로 어느 시간대에 무료체험 유저들이 가장 많이 방문하는지 살펴보았다.

[그림 **II-5]** 시간대별 지점 방문 건 수



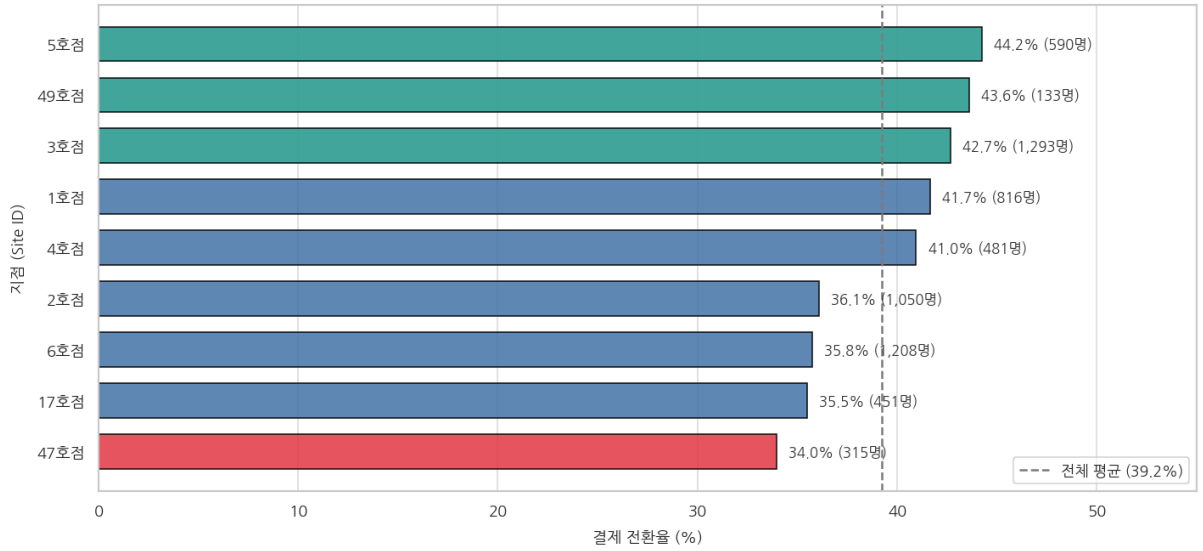
분석 결과, 모든 지점에서 점심 직후인 **13~14**시에 가장 높은 방문 피크가 나타났다. 특히 지점 **3**, **6**, **2**가 전 시간대에 걸쳐 가장 높은 이용을 보이고 있다. 지점별로 방문 건수의 차이가 확연했다.

다음 분석 단계로 지점별로 결제 전환율의 차이고 있는지 확인하고자 했으며 다음과 같은 결과가 나타났다.

[표 II-15] 주 이용 지점별 고유 유저 수 및 결제 전환율

지점 **id**	고유 유저 수**(명)**	결제 전환율**(%)**
5	590	44.2
49	133	43.6
3	1,293	42.7
1	816	41.7
4	481	41.0
2	1,050	36.1
6	1,208	35.8
17	451	35.5
47	315	34.0

[그림 II-6] 주 이용 지점별 유저 결제 전환율 순위



주 이용 지점별 결제 전환율은 위와 같이 **34~44%** 범위에 분포하며, 표면적으로는 최고치와 최저치 간 약 **10%p** 차이가 존재한다.

그러나 아래 요인들이 전환율을 왜곡하고 있어 해당 차이가 '지점의 품질 차이' 때문이라고 결론 내리기는 어렵다.

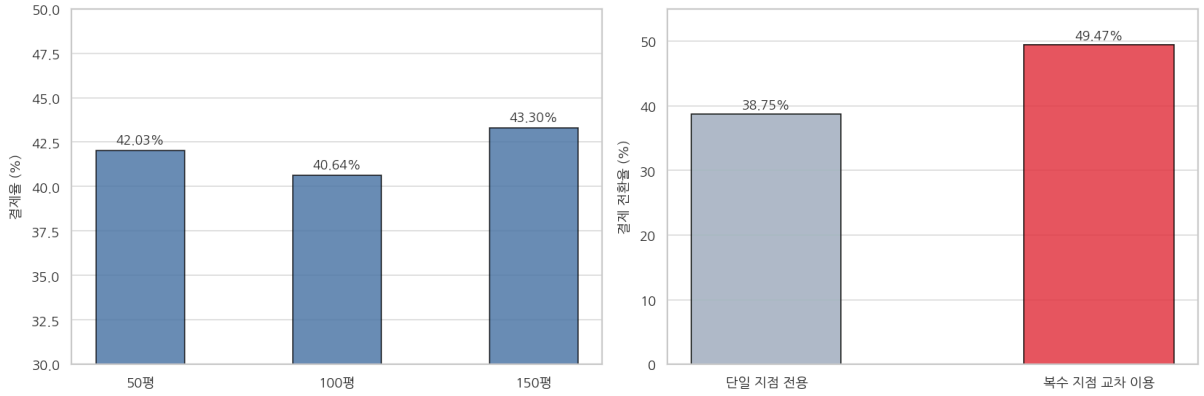
[표 II-16] 지점별 운영일수

지점	운영일수
1, 2, 3, 4	965일 이상 (초기 거점 추정)
5	772
4	772
6	512
17	512
47	389
49	255

먼저 지점별 운영일수를 살펴보면, 운영일수가 짧은 지점의 경우 방문자 수 및 유저 풀이 작음을 알 수 있다. 즉, 운영일수 차이 때문에 전환율이 달라 보이는 것이지 지점 자체의 품질 차이라고 해석하기는 어려워 보인다.

특히 **49**호점은 운영일수가 **255**일로 매우 짧아, 결제 전환율이 **43.6%**로 높게 나타난 것은 단순히 표본 크기 작아서 발생한 통계적 변동성일 가능성이 높다.

[그림 II-7] 지점 면적별**(**평수**) &** 지점 이용 형태별**(**단일 **vs** 복수**)** 결제 전환율



한편, 면적별 결제 전환율을 고려하면 평수와 상관없이 **40~43%** 내외로 거의 동일하게 나타남에 따라 지점 규모는 전환율에 거의 영향을 미치지 않는 것으로 판단하였다.

또한 복수 지점 이용자의 결제 전환율(49.5%)이 단일 지점 이용자(38.8%)보다 높게 나타났는데, 이러한 복수 이용자에 대한 지점별 비중 정도가 지점별 전환율 차이에 기여했을 가능성도 존재한다. 즉, 지점별 환경 품질에 따른 전환률 차이가 아닌, 전환율이 높은 복수 지점 이용자를 주 고객군으로 삼고있는 비중 정도에 따라 지점별 전환률 차이가 발생할 가능성이 있다는 의미이다.

따라서 표면적으로는 주 이용 지점별 유저의 결제 전환율이 **34~44%** 범위로 나타나 지점 간 전환율 차이가 존재하는 것처럼 보이나, 지점별 운영일수·유저 특성·체류시간 등을 함께 고려하면 지점 자체의 품질 차이로 인한 전환율 차이는 거의 존재하지 않을 것으로 판단된다.

즉, 지점별 결제 전환율은 각 지점의 물리적 특성보다는 이용자의 행동 패턴에 의해 결정되는 경향이 있을 것으로 보인다.

3-4. 체류시간 분포

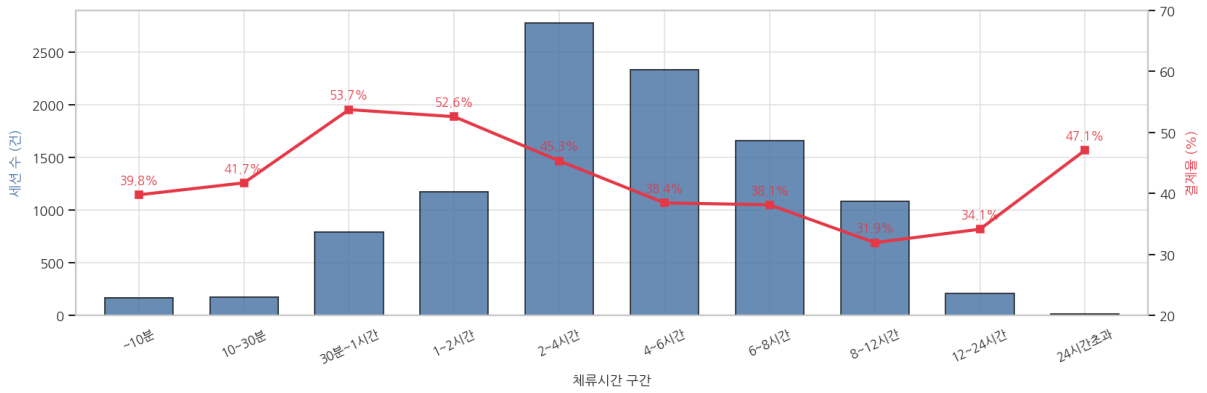
다음으로는 체류시간별 세션 분포와 결제 전환율을 살펴보았다.

[표 II-17] 체류시간 구간별 세션 수 및 결제 전환율

체류시간	세션 수(건)	결제 전환율(%)
~10분	166	39.8
10~30분	175	41.7
30분~1시간	795	53.7
1~2시간	1,174	52.6
2~4시간	2,778	45.3

4~6시간	2,334	38.4
6~8시간	1,663	38.1
8~12시간	1,087	31.9
12~24시간	211	34.1
24시간 초과	17	47.1

[그림 II-8] 체류시간 구간별 세션 수 및 결제 전환율

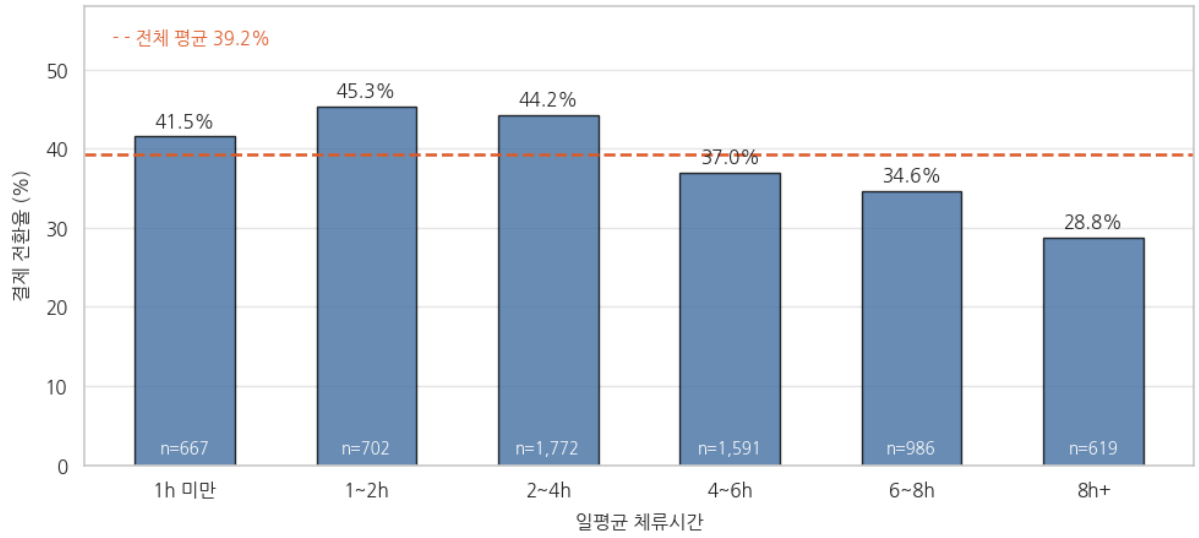


분석 결과, 체류시간과 결제 전환율은 단순한 비례 관계가 아닌 비선형적인 패턴을 보였다. 세션 수 기준으로는 30분~2시간 구간에서 결제 전환율이 53~54%로 가장 높았으며, 이후 2시간 이상 구간에서는 체류시간이 길어질수록 전반적으로 전환율이 하락하는 경향이 나타났다.

[표 II-18] 일평균 체류시간별 유저 수 및 결제 전환율

체류시간	유저 수(명)	결제 전환율(%)
1시간 미만	667	41.5
1~2시간	702	45.3
2~4시간	1,772	44.2
4~6시간	1,591	37.0
6~8시간	986	34.6
8시간 이상	619	28.8

[그림 II-9] 일평균 체류시간별 결제 전환율



유저별 일평균 체류시간을 기준으로 살펴보아도 **1~2**시간(**45.3%**), **2~4**시간(**44.2%**) 구간의 전환율이 전체 평균(**39.2%**)을 상회한 반면, **4**시간 이상에서는 전환율이 점차 낮아졌다. 특히 **8**시간 이상 지점을 이용한 유저의 전환율은 **28.8%**로 가장 낮게 나타났다.

이에 따라 무료체험 유저의 체류시간이 길수록 전환 가능성이 높아지는 것은 아니며, 오히려 **1~4**시간 수준의 이용자에서 상대적으로 높은 전환율이 관찰되는 패턴을 확인할 수 있었다.

즉, 무료체험 이용자의 결제 전환율을 개선하기 위해서는 단순히 장시간 이용을 유도하기보다 체험 과정에서 적절한 수준의 이용 경험을 형성하도록 도움을 주는 것이 중요할 가능성을 보여준다.

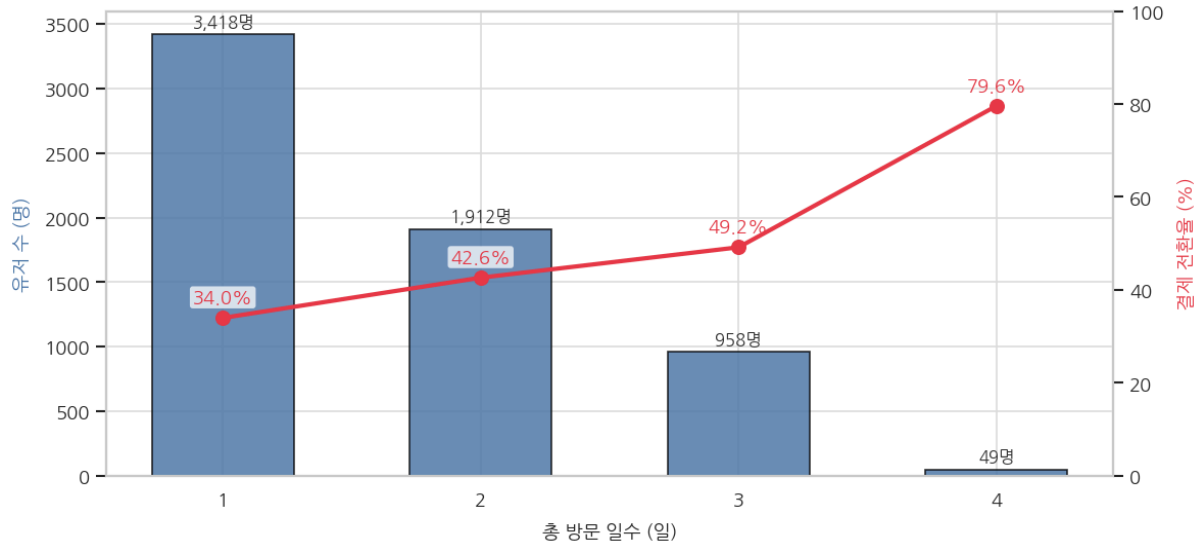
3-5. 방문일수 및 재방문 패턴

무료체험은 최대 3일 제공되지만, 실제 이용 패턴은 다음과 같았다.

[표 II-19] 방문일수별 유저 수 및 결제 전환율

총 방문 일수	유저 수(명)	유저 비율(%)	결제 전환율(%)
1	3,418	53.9	34.0
2	1,912	30.2	42.6
3	958	15.1	49.2
4	49	0.8	79.6

[그림 II-10] 방문일수별 유저 수 및 결제 전환율 추이



방문일수가 증가할수록 결제 전환율도 뚜렷하게 상승하는 경향이 확인되었다. 1일만 방문한 유저의 결제 전환율은 34.0%, 2일 방문 유저는 42.6%, 3일 연속 방문한 유저는 49.2%로 나타났다.

즉, 무료체험 기간을 모두 활용하는 이용자일수록 결제 전환 가능성이 높은 것으로 나타나, 무료체험 운영에서 재방문을 유도하는 전략을 고려할 필요성을 확인하였다.

다만, 일부 유저(49명, 0.8%)는 4일 이상 방문 기록이 나타났는데, 이는 표본이 작고 원인이 특정되지 않아 본 분석에서는 참고 수치로만 제시하며 핵심 근거로는 1~3일 구간의 추세를 사용하였다.

4. 1차 모델링 - 무료체험 수요 예측

4-1. 배경 및 전체 흐름

1차 모델링의 목표는 지점·요일·시간대별 동시 체류 인원(수요)을 예측하는 것이었다. 초기에는 회귀 분석을 기반으로 절대 인원수를 직접 예측하는 접근을 시도하였으나, 시간대별 변동성이 크고 체험 이용 자체가 소규모로 이루어지는 특성상 예측 정확도가 낮았다(R^2 약 0.10~0.20 수준).

이에 따라, 수요(이용도)를 연속값이 아닌 등급(Level)으로 단순화하여 분류 모델로 전환하였다. 랜덤포레스트 기반 분류 모델이 가장 안정적인 성능(Macro F1 약 0.52~0.54)을 보였으나, '높음' 등급조차 실제 동시 체류 인원이 평균 1~2명 수준에 불과해 운영 전략을 직접적으로 도출하기에는 실용성이 낮았다.

따라서 1차 모델링은 운영 효율화 모델로 활용하기보다는, 2차 모델링에서 이용도(Level)를 행동 맥락 변수로 활용하는 보조적 역할로 정리하였다.

(관측 단위(해상도)를 1시간 → 4구간(야간/오전/오후/저녁) → 일별로 넓혀가며 재시도했다. 그러나 회귀만으로는 절대 인원수를 정밀하게 맞추는 데 한계가 있어, 최종적으로 회귀 대신 3단계 등급 분류(수요없음/보통/높음)로 전환했고, 4구간 해상도의 등급 분류 모델을 1차 최종 채택 모델로 결정했다.)

4-2. 1시간 단위 연속값 회귀 예측

특정 지점에 대한 요일 및 시간대(1시간 단위)의 동시 체류 인원(명)을 직접 예측하기 위해 다음과 같이 요일, 시간대, 지점 ID, 과거 방문 수, 공휴일 여부 등의 기본 특성을 이용하여 회귀 모델(Linear, RandomForest, XGBoost)을 시도해보았다.

[표 II-20] 1시간 단위 회귀 모델 변수 개요

구분	변수명	의미
종속 변수	concurrent_count	1시간 단위 동시 체류 인원
독립 변수	site_id	지점id
	area_pyeong	지점 평수
	dow_num	요일
	hour	시간
	is_weekend	주말 여부

	month	월
	site_tenure_days	지점 운영 경과일수
	hist_avg_site_dow_hour	지점x요일x시간대별 평균 동시 체류 인원
	rolling_7d_avg	최근 7일 이동평균 동시 체류 인원

[표 **II-21] 1**시간 단위 회귀 모델 분석 결과

모델	**MAE**	**RMSE**	**R^2**
RandomForest	0.451	0.698	0.198
XGBoost	0.464	0.731	0.119
LightGBM	0.456	0.732	0.118

모델 시도 결과, R^2 = 0.1~0.2 수준으로 예측력이 매우 낮았으며, 실제 동시 체류 인원이 0명인 시간대 구간이 약 75%에 달하고 개별 시간대 변동성이 커서 회귀 모델이 패턴을 포착하기 어려워, 운영팀이 해당 결과를 활용하기에는 **'**숫자를 맞추는 정확도**'**가 부족하다고 판단하였다.

4-3. 4구간(오전/오후/저녁/심야) 단위 회귀 예측

이에 따라 1시간 단위 예측이 불안정하다는 점을 고려하여, 시간대를 오전/오후/저녁/심야 4개 구간으로 묶어 변동성을 완화하는 방식으로 단위를 확장하여 동일한 회귀 모델(Linear, Random Forest, XGBoost)을 4구간 단위로 재적용하였다.

[표 **II-22] 4**구간 단위 회귀 모델 변수 개요

구분	변수명	의미
종속 변수	occ_mean	4구간 평균 동시 체류 인원 (연속값)
	site_id	지점id
	area_pyeong	지점 평수
	weekday	요일
	is_weekend	주말 여부
	time_group_idx	4구간(심야/오전/오후/저녁)

독립 변수	site_wd_tg_avg	지점×요일×구간 평균 동시 체류 인원
	lag_1d/1w/2w	1일/1주/2주 전 동시 체류 인원
	roll_4w/7d	최근 4주/7일 이동평균 동시 체류 인원
	register_lag_1d	1일 전 무료체험 신청 인원
	register_recent_4d/7d	최근 4일/7일 전 무료체험 신청 인원

[표 II-23] 4구간 단위 회귀 모델 분석 결과

모델	**MAE**	**RMSE**	**R^2**
Baseline	0.365	0.584	0.202
RandomForest	0.341	0.551	0.289
XGBoost	0.337	0.547	0.301
LightGBM	0.339	0.548	0.297

그 결과, R^2 = 0.29~0.30 수준으로 1시간 단위보다 성능은 개선되었으나, 오후 구간의 변동성이 여전히 크고, 무료체험 수요 자체가 작아 예측 오차가 크게 발생하여 '운영 의사결정에 활용할 만큼 신뢰할 수 있는 수준'에는 미치지 못하였다.

4-4. 요일 단위 회귀 예측

즉, 시간대 예측이 구조적으로 어렵다고 판단하여, 단위를 더 크게 묶어 요일 단위로 일별 총 방문자 수를 예측하는 방식으로 전환하여 동일 회귀 모델을 요일 단위에 적용하였다.

[표 II-24] 요일 단위 회귀 모델 변수 개요

구분	변수명	의미
종속 변수	occ_mean	일별 평균 동시 체류 인원
	site_id	지점id
	area_pyeong	지점 평수
	weekday	요일

독립 변수	is_weekend	주말 여부
	site_wd_avg	지점 × 요일별 평균 동시 체류 인원
	lag_1d/1w/2w	1일/1주/2주 전 동시 체류 인원
	roll_4w/7d	최근 4주/7일 이동평균 동시 체류 인원
	register_lag_1d	1일 전 무료체험 신청 인원
	register_recent_4d/7d	최근 4일/7일 전 무료체험 신청 인원

[표 II-25] 요일 단위 회귀 모델 분석 결과

모델	**MAE**	**RMSE**	**R^2**
Baseline	0.305	0.434	0.064
RandomForest	0.273	0.397	0.215
XGBoost	0.270	0.396	0.222
LightGBM	0.273	0.399	0.209

[표 II-26] 실제 평균인원과 예측 평균인원 비교 **(XGB** 기준**)**

요일	실제 평균인원	예측 평균인원
월	0.277	0.256
화	0.324	0.369
수	0.389	0.413
목	0.417	0.401
금	0.362	0.367
토	0.382	0.283
일	0.347	0.312

분석 결과, R^2 = 0.21~0.22 수준으로 1시간 단위보다는 개선된 성능을 보였으나, 4구간 시간 단위보다는 낮은 성능을 나타냈다. 요일별 평균 방문자 수에 일정한 패턴(수요일·목요일이 가장 붐비는 요일)이 있는 것을 모델이 잡아내긴 하였으나, 개별 일자 변동성이 커서 여전히 예측력이 낮고, 예약 기반이 아닌 자율 방문이라는 공유오피스 무료체험 유저의 특성상 요일 단위 수요도 안정적으로 예측하기 어렵다는 점을 확인하였다.

4-5. 1시간 단위 등급 분류 전환

이에 따라, 연속값 예측이 구조적으로 어려운 문제라고 판단하여, 운영팀이 실제로 활용할 수 있도록 이용도를 상태(수요 없음/보통/높음) 등급에 따라 구분하는 분류 모델(Logistic, RandomForest, XGBoost)로 방향을 전환하였다.

[표 **II-27] 1**시간 단위 등급 분류 모델 변수 개요

구분	변수명	의미
종속 변수	level	수요 수준 (수요없음/보통/높음, 3-class)
독립 변수	site_id	지점id
	area_pyeong	지점 평수
	weekday	요일
	hour	시간대
	is_weekend	주말 여부
	site_wd_hour_avg	지점 × 요일 × 시간별 평균 동시 체류 인원
	lag_1d/1w/2w	1일/1주/2주 전 동시 체류 인원
	roll_4w/7d	최근 4주/7일 이동평균 동시 체류 인원

[표 **II-28] 1**시간 단위 등급 분류 모델 분석 결과

모델	**Macro F1**	**Balanced Accuracy**
RandomForest	0.521	0.574
XGBoost	0.520	0.577
LightGBM	0.519	0.578

[표 **II-29]** 이용도 등급별 정밀도와 재현율

모델	수요 없음		보통		높음	
	정밀도	재현율	정밀도	재현율	정밀도	재현율

RandomForest	0.898	0.690	0.309	0.533	0.322	0.499
XGBoost	0.897	0.677	0.309	0.555	0.322	0.498
LightGBM	0.899	0.673	0.305	0.547	0.322	0.513

분석 결과, Macro F1은 약 0.52 수준으로 등급 분류 자체는 가능한 것으로 보였다. 다만, '높음' 등급의 재현율(recall)이 약 0.50~0.51 수준이고 '보통'·'높음'의 정밀도(precision)가 약 0.31~0.32 수준으로 그 수치가 낮아 안정적인 분류가 어려웠다. 이에 대해 1시간이라는 단위 간격이 상대적으로 좁아 개별 시간대의 노이즈에 민감하게 반응하여 발생한 문제일 가능성이 있다고 판단하여, 시간 단위를 넓혀 다시 시도해보기로 하였다.

4-6. 4구간 단위 등급 분류 전환 - 1차 최종 모델

4구간(오전/오후/저녁/심야) 단위에서 '수요없음/보통/높음' 3단계 등급으로 문제를 재정의하여 분류 모델을 다시 시도하였다.

[표 II-30] 4구간 단위 등급 분류 모델 변수 개요

구분	변수명	의미
종속 변수	level	수요 수준 (수요없음/보통/높음, 3-class)
독립 변수	site_id	지점id
	area_pyeong	지점 평수
	weekday	요일
	is_weekend	주말 여부
	time_group_idx	시간대 (오전/오후/저녁/심야)
	site_wd_tg_avg	지점 x 요일 x 시간대별 평균 동시 체류 인원
	lag_1d/1w/2w	1일/1주/2주 전 동시 체류 인원
	roll_4w/7d	최근 4주/7일 이동평균 동시 체류 인원
	register_lag_1d	1일 전 무료체험 신청 인원
	register_recent_4d/7d	최근 4일/7일 무료체험 신청 인원

[표 II-31] 4구간 단위 등급 분류 모델 분석 결과

모델	**Macro F1**	**Balanced Accuracy**
RandomForest	0.544	0.573
XGBoost	0.525	0.557
LightGBM	0.512	0.547

[표 II-32] 이용도 등급별 정밀도와 재현율

모델	수요 없음		보통		높음	
	정밀도	재현율	정밀도	재현율	정밀도	재현율
RandomForest	0.835	0.717	0.395	0.460	0.363	0.542
XGBoost	0.833	0.696	0.395	0.462	0.317	0.512
LightGBM	0.832	0.684	0.378	0.435	0.299	0.523

모델 성능 비교 결과, RandomForest의 Macro F1이 약 0.54로 1시간 단위(약 0.52)보다는 성능이 개선되었으며, '높음' 등급의 재현율(recall) 또한 0.50에서 0.54로 수치가 상승하여 등급을 보다 안정적으로 맞힐 수 있게 되었음을 확인하였다.

[표 II-33] 등급별 실제 인원수 통계

등급	**mean**	**median**	**min**	**max**
높음	2.04	1.83	1.00	17.00
보통	0.66	0.67	0.25	1.50
수요 없음	0.01	0.00	0.00	0.17

다만, 지점별로 데이터 기반 임계값(75% 분위수)을 사용해 등급을 나눠 살펴본 결과, '높음' 등급이라 해도 실제 인원수는 평균 1~2명 수준으로 나타났다. 즉, 등급명만 보면 무료 이용자가 몰려 '붐비는' 시간대인 것처럼 보이나 실제 절대 인원은 매우 작아 등급 정보만으로는 운영 전략을 도출하기에는 실용성이 낮다는 한계가 있었다.

4-7. 한계점 및 **2**차 모델링 필요성

이에 따라, 1차 모델링은 '무료체험 수요를 정밀하게 예측하는 것'에 한계가 있음을 인정하고, 해당 과정에서 도출된 이용도 등급**(Level)**을 이후 **'**유료 결제 전환 예측**'**에 대한 **2**차 모델링에서 행동 맥락을 설명하는 주요 보조 변수**(feature)**로 활용하여 '무료체험 이용자가 몰려 붐비는 시간대에 체험한 유저인지 여부가 결제 전환에 영향을 주는가'를 확인하는 방향을 채택하였다.

5. 2차 모델링 **-** 결제 전환 예측

5-1. 배경 및 전체 흐름

2차 모델링의 목표는 무료체험 이용자의 행동 패턴이 결제 전환에 어떤 영향을 미치는지 규명하는 것이었다. 이를 위해 단일 모델을 바로 구축한 것이 아니라,

- **Base Model:** 기본 행동 변수만 사용
- **Base + Level:** 1차 모델링에서 생성한 이용도 등급(level_idx) 추가
- **Base + Level + Dropout:** 재방문 여부(dropout) 추가
- **Base + Level + Dropout + Stay_growth:** 체류시간 변동성(stay_growth) 추가

와 같이 변수를 단계적으로 확장하며 모델을 개선하는 방식으로 진행하였다.

초기 Base Model은 체류시간 중앙값, 최빈 방문 요일, 시간대 등 기본 행동 변수를 중심으로 구성되었으며, AUC 약 0.60 수준으로 전환 예측이 가능함을 확인하였다. 이후 1차 모델링에서 생성한 이용도 등급(level_idx)을 추가하여 행동 맥락을 강화하였고, 재방문 여부(dropout)를 포함했을 때 모델 성능이 가장 크게 개선(AUC 약 0.64)되었다.

그러나 dropout은 유저 행동의 결과 변수로서 운영팀이 직접 개입할 수 있는 원인적 행동 신호가 아니라는 한계가 있었다. 이를 보완하기 위해 유저의 체험 경험의 질을 반영하는 체류시간 변동성(stay_growth)을 추가하였고, 예측 성능(AUC 약 0.64)과 해석력 및 운영 적용성을 모두 충족하는 모델로 발전하였다.

따라서 2차 모델링은 단순히 성능이 높은 모델을 선택하는 것이 아니라, 전환을 설명하는 행동적 원인 변수를 식별하고 이를 기반으로 운영 전략으로 연결 가능한 모델을 구축하는 과정으로 정리하였다.

5-2. 데이터 준비

전환 여부는 체험 종료 후 결정되므로 유저 1명당 1행 원칙(데이터 누수 방지)에 따라, 유저별 방문 기록을 mode 및 median으로 요약한 유저별 집계 테이블을 새로 생성해 사용하였다. 이용도 등급(level_idx)은 1차 모델링 중 4구간 등급 분류에서 만든 결과를 그대로 재사용해 (site_id, date, time_group) 기준으로 매칭하였다. 참고로, 이용도 등급별

실제 전환율을 사전 확인한 결과, '높음' 등급의 전환율이 가장 낮게 나타나 사전 신호를 확인할 수 있었다.

[표 II-34] 이용도 등급별 실제 전환율

Level	전환율
높음	35.3%
보통	40.6%
수요 없음	44.1%

5-3. Train/Test 분리

학습 및 검증 데이터는 1차와 동일한 기준(2023-09-01 기준)으로 분리하였다.

5-4. Base Model - 기본 행동 변수 기반 전환 예측

무료 체험 이용자의 기본 행동 특성만으로 결제 전환 여부를 예측할 수 있는지 확인해보았다.

[표 II-35] Base 모델 변수 개요

구분	변수명	의미
종속 변수	is_payment	결제 전환 여부
독립 변수	site_id	최빈 방문 지점 id
	area_pyeong	최빈 방문 지점 평수
	weekday_num	최빈 요일
	is_weekend	최빈 방문 요일이 주말인지 여부
	time_group_idx	최대 시간대 그룹 라벨링 0: 야간 1: 오전 2: 오후 3: 저녁

	stay_minute	유저의 1회 방문당 체류 시간 중앙값

[표 II-36] Base 모델 분석 결과

모델	**Macro F1**	**Balanced Accuracy**	**AUC**	재현율**(**결제**)**
RandomForest	0.554	0.576	0.602	53.3%
XGBoost	0.551	0.550	0.581	29.1%
LightGBM	0.536	0.560	0.574	53.3%

Base Model 결과 AUC가 약 0.57~0.60 수준으로 기본 행동 변수만으로도 유료 결제 전환 예측 자체는 가능함을 확인하였다.

5-5. Base + Level - 이용도 추가

이번에는 1차 모델링에서 도출한 이용도 등급(Level)을 추가하여, 결제 전환 예측에 '이용 환경의 맥락'을 반영해보았다.

[표 II-37] Base + Level 모델 변수 개요

구분	변수명	의미
종속 변수	is_payment	결제 전환 여부
독립 변수	site_id	최빈 방문 지점 id
	area_pyeong	최빈 방문 지점 평수
	weekday_num	최빈 요일
	is_weekend	최빈 방문 요일이 주말인지 여부
	time_group_idx	최대 시간대 그룹 라벨링 0: 야간 1: 오전 2: 오후 3: 저녁
	stay_minute	유저의 1회 방문당 체류 시간 중앙값

	level_idx	유저가 첫 방문한 시점의 공유오피스 이용도 등급 0: '수요 없음' 1: '보통' 2: '높음'

[표 II-38] Base + Level 모델 분석 결과

모델	**Macro F1**	**Balanced Accuracy**	**AUC**	재현율**(**결제**)**
RandomForest	0.569	0.603	0.627	60.7%
XGBoost	0.566	0.564	0.608	34.4%
LightGBM	0.543	0.573	0.596	56.6%

Base와 Base + Level 두 모델에서 성능이 가장 우수하게 나타난 RandomForest 기준, AUC가 약 0.60에서 0.63으로 상승하고, Macro F1도 약 0.55에서 0.57로 상승하여 Base Model 대비 성능이 소폭 개선되었다. 즉, 이용도 정보가 결제 여부를 구별하는 데 실제로 도움이 되는 신호로 보인다.

5-6. Base + Level + Dropout - 재방문 여부 추가

성능이 가장 우수하게 나타난 RandomForest에 재방문 여부(dropout)를 추가하여 '1일만 방문하고 끝냈는지, 다시 왔는지'라는 행동 결과 변수가 결제 예측 성능 개선에 도움이 되는지 확인해보았다.

[표 II-39] Base + Level + Dropout 모델 변수 개요

구분	변수명	의미
종속 변수	is_payment	결제 전환 여부
	site_id	최빈 방문 지점 id
	area_pyeong	최빈 방문 지점 평수
	weekday_num	최빈 요일
	is_weekend	최빈 방문 요일이 주말인지 여부

독립 변수	time_group_idx	최대 시간대 그룹 라벨링 0: 야간 1: 오전 2: 오후 3: 저녁
	stay_minute	유저의 1회 방문당 체류 시간 중앙값
	level_idx	유저가 첫 방문한 시점의 공유오피스 이용도 등급 0: '수요 없음' 1: '보통' 2: '높음'
	dropout	재방문 포기/이탈 여부 플래그

[표 II-40] Base + Level + dropout 모델 분석 결과

모델	**Macro F1**	**Balanced Accuracy**	**AUC**	재현율	정밀도
RandomForest	0.580	0.600	0.640	54.5%	37.2%

분석 결과, AUC가 0.627에서 0.640으로, Macro F1이 0.569에서 0.580으로 소폭 상승하여 성능이 개선됨을 확인하였다. 즉, 재방문 여부(dropout)는 결제 전환 예측에 도움이 되는 정보일 것으로 판단된다.

[표 II-41] Random Forest 모델의 피처 중요도

변수	중요도 **(%)**
stay_minute	**40.8**
dropout	**14.6**
weekday_num	10.9
site_id	10.4
time_group_idx	9.8
level_idx	7.2
area_pyeong	4.0
is_weekend	2.3

Random Forest 모델의 피처 중요도 산출 결과에서도 체류시간(40.8%)과 재방문 여부(14.6%)는 결제 전환 예측의 핵심 구성 요소로 확인되었다.

5-7. Base + Level + Dropout + Stay_growth - 체류시간 변동성 추가

이에 따라 체류시간과 재방문 여부를 종합적으로 반영하는 '마지막 방문 체류시간 - 첫 방문 체류시간'으로 산출한 체류시간 변동성(stay_growth)을 추가하여 결제 전환 예측을 다시 시도해보았다.

[표 II-42] Base + Level + Dropout + Stay_growth 모델 변수 개요

구분	변수명	의미
종속 변수	is_payment	결제 전환 여부
독립 변수	site_id	최빈 방문 지점 id
	area_pyeong	최빈 방문 지점 평수
	weekday_num	최빈 요일
	is_weekend	최빈 방문 요일이 주말인지 여부
	time_group_idx	최대 시간대 그룹 라벨링 0: 야간 1: 오전 2: 오후 3: 저녁
	stay_minute	유저의 1회 방문당 체류 시간 중앙값
	level_idx	유저가 첫 방문한 시점의 공유오피스 이용도 등급 0: '수요 없음' 1: '보통' 2: '높음'
	dropout	재방문 포기/이탈 여부 플래그
	stay_growth	첫 방문 대비 마지막 방문의 체류시간 변화량 (마지막 방문 stay_minute − 첫 방문 stay_minute)

[표 II-43] Base + Level + dropout + stay_growth 모델 분석 결과

모델	**Macro F1**	**Balanced Accuracy**	**AUC**	재현율	정밀도
RandomForest	0.579	0.596	0.637	52.0%	37.1%

분석 결과, Macro F1, AUC와 정밀도는 0.001~0.004% 단위로 감소하였고 재현율의 경우 0.025% 낮아짐에 따라, 전반적으로 오히려 성능이 미세하게 떨어지며 체류시간 변화량(stay_growth)이 모델을 유의미하게 개선하지 못하는 것으로 나타났다.

다만, 피처 중요도의 결과에 따라 체류시간 변화량까지 포함하여 전환율을 예측해야 한다는 판단 하에 해당 변수를 최종 변수 구성 요소로 채택하기로 결정하였다.

6. 모델 최종 선택

최종 모델은 Random Forest로 하였다. 학습과 평가는 2023-09-01을 기준으로 분리한 유저별 집계 데이터(학습 5,438명, 검증 897명)에서 동일한 설정(n_estimators=300, max_depth=8, min_samples_leaf=10, class_weight='balanced', random_state=42)으로 수행하였으며, 후보는 재방문 여부(dropout)까지 반영한 모델과 여기에 체류시간 변화량(stay_growth)을 추가한 모델 두 가지였다.

[표 **II-44]** 최종 모델 후보 성능 비교 **(Random Forest)**

모델	변수 수	**AUC**	**Macro F1**	재현율**(**결제**)**
Base + level_idx + dropout	8개	0.640	0.580	54.5%
Base + level_idx + dropout + stay_growth (최종**)**	**9**개	**0.637**	**0.579**	**52.0%**

[표 **II-45]** 최종 모델 후보 변수 중요도 비교 **(Random Forest)**

모델	**stay_minute** 중요도	**dropout** 중요도	**stay_growth** 중요도
Base + level_idx + dropout	40.8%	14.6%	-
Base +	**37.3%**	**9.2%**	**16.2%**

level_idx + dropout + stay_growth (최종**)**			

두 모델의 예측 성능은 거의 같았다. stay_growth를 추가하기 전 모델의 AUC는 0.640, 추가한 모델은 0.637로 0.003 낮아졌고, Macro F1은 0.580에서 0.579로, 재현율은 54.5%에서 52.0%로 소폭 감소하였다. 정밀도는 37.2%에서 37.1%로 사실상 같았다. 따라서 예측 성능만을 기준으로 하면 stay_growth를 추가하지 않은 모델이 근소하게 우수하다.

그럼에도 stay_growth를 포함한 모델을 최종안으로 채택하였다. 모든 모델에서 가장 중요한 변수는 처음부터 끝까지 체류시간(stay_minute)이었고(중요도 40.8%), 재방문 여부(dropout)를 추가했을 때 성능이 개선되어 재방문 정보 역시 결제 전환을 설명하는 의미 있는 신호임을 확인하였다. 여기에 EDA에서도 체류시간이 결제 전환율과 밀접한 관계를 보였다. 이에 재방문 여부와 체류시간이라는 두 핵심 신호를 함께 담을 수 있는 변수가 필요하다고 판단하였다.

stay_growth(마지막 방문의 체류시간 − 첫 방문의 체류시간)는 재방문했는가와 체류시간이 어떻게 변했는가를 동시에 반영하는 변수이다. 실제로 stay_growth는 최종 모델에서 중요도 16.2%로 dropout(9.2%)보다 높게 나타났다. 따라서 AUC 0.003 정도의 차이보다 재방문과 체류시간이라는 핵심 이용 행동을 함께 설명하고 운영 전략으로 연결할 수 있다는 점을 우선하여 stay_growth를 포함한 모델을 최종 모델로 선택하였다.

다만 최종 모델의 AUC는 약 0.64로 정밀한 개인 단위 예측에는 한계가 있으므로, 결제 가능성이 높은 고객군을 파악하고 운영 전략을 보조하는 용도로 활용하는 것이 적절하다.

III. 결론

1. 분석 결과 요약

본 분석은 무료체험 신청자 9,624명 중 실제 방문한 6,335명의 이용 로그를 바탕으로 수요 패턴, 결제 전환과 이용행태의 관계, 결제 전환 예측 가능성을 살펴보았다. 수요는 오후(12~17시 59분)에 전체 방문의 52.3%, 수·목·금 등 주중에 77.8%가 집중되었다. 그러나 이용이 몰리는 시간대가 전환에 유리한 것은 아니었다. 전환율은 오후가 39.1%로 가장 낮았고, 방문 비중이 15.9%에 불과한 저녁이 54.7%로 가장 높았다. 방문 요일과 지점 평수는 전환율 차이를 뚜렷하게 설명하지 못했다. 지점별 전환율(34~44%)도 운영일수와 복수 지점 이용자 비중의 영향이 커서 지점 자체의 품질 차이로 보기는 어려웠다.

이용행태 중에서는 체류시간과 재방문 여부가 전환과 가장 밀접했다. 체류시간은 길수록 유리한 것이 아니었다. 세션 기준으로 30분~2시간 구간의 전환율이 53%대로 가장 높았고, 유저별 일평균 8시간 이상 체류한 경우에는 28.8%까지 낮아졌다. 방문일수가 1일, 2일, 3일로 늘수록 전환율은 34.0%, 42.6%, 49.2%로 뚜렷하게 상승했고, 재방문 유저(45.4%)와 재방문 포기 유저(33.9%)의 차이는 11.5%p였다.

모델링에서는 1차 수요 예측의 한계가 확인되었다. 회귀 모델의 R^2는 0.10~0.20에 그쳤고, 3단계 등급 분류의 Macro F1은 0.52~0.54였다. '높음' 등급의 실제 동시 체류 인원도 1~2명 수준이어서, 이 등급은 2차 모델의 보조 변수로 활용하였다. 2차 결제 전환 예측에서 Random Forest의 AUC는 기본 변수 0.602, 이용도 등급 추가 0.627, 재방문 여부 추가 0.640으로 단계적으로 개선되었다. 변수 중요도는 체류시간 40.8%, 재방문 여부 14.6%였다. 체류시간 변화량(stay_growth)은 AUC를 개선하지 못했지만(0.640 → 0.637), 체류시간과 재방문 정보를 함께 반영해 해석력을 높일 수 있어 최종 모델에 포함하였다. 튜닝과 다른 모델군 비교에도 AUC는 0.58~0.63 범위에 머물러, 성능 한계는 모델보다 변수의 설명력에서 비롯된 것으로 판단하였다. 이에 최종 모델은 개인 단위의 정밀 예측보다 운영 전략을 보조하는 용도로 적합하다.

2. 제안 및 기대효과

본 분석에서 도출된 인사이트를 운영에 반영하기 위한 개선 방향을 제안한다. 다만 본 분석은 이용행태와 결제 전환의 관계를 관찰한 것이며 인과 효과를 확인한 것은 아니므로, 각 제안은 A/B 테스트로 효과를 검증하면서 단계적으로 적용하는 것을 전제로 한다.

분석결과 지점의 물리적 특성보다 이용자의 행동 패턴(체류시간, 재방문, 이용 시간대)이 결제 전환과 더 밀접하게 나타났으며, 이에 체류시간 관리, 재방문 유도, 저녁 시간대 활용 등 우선 검토할 과제를 제시한다.

1) 체류시간 기반 운영 개선

- 배경

분석 결과 체류시간은 결제 전환율을 설명하는 핵심 변수로 확인되었다. 특히 체류시간이 길수록 전환율이 낮아지는 경향이 뚜렷하게 나타났으며, 4시간 미만 이용자의 전환율은

43.9%(3,141명)였고, 4시간 이상 이용자는 34.6%(3,196명)로 전체 평균(39.2%)보다 낮았다. 특히 8시간 이상 이용자의 전환율은 28.8%로 가장 낮았다.
다만 결제 시점 데이터가 없어 체류시간과 결제의 선후관계는 확인하지 못했다. 이 결과만으로 장기 체류가 전환을 낮춘다고 보기는 어렵고, 업무 목적으로 공간을 오래 이용하는 유저의 결제 의향이 원래 낮을 수도 있는 가능성도 있다. 따라서 본 결과는 짧고 집중적인 체험이 전환에 더 유리할 가능성을 시사하는 정도로 해석하며, 실제 효과는 A/B 테스트로 확인할 필요가 있다. 이는 무료체험 운영에서 '오래 머무르게 하는 것'보다 '짧고 효율적인 경험을 제공하는 것'이 전환율 향상에 중요한 요인일 가능성을 시사한다.

- 제안

체류시간과 결제 전환의 인과관계가 확인되지 않은 상황에서 이용시간 상한을 바로 적용하면 실제로 장시간 이용이 필요한 고객의 체험 경험을 제한할 수 있다. 따라서 체류시간을 강제로 제한하기보다 단계적인 방식으로 정책 효과를 확인할 필요가 있다. 우선 체류시간이 4시간 넘는 시점에 유료 멤버십 안내, 장시간 이용에 적합한 요금제 또는 가입 혜택을 소개하는 메시지를 자동으로 발송하는 방안을 제안한다. 이를 통해 장시간 체류 고객에게 이용을 중단하도록 요구하지 않으면서 자연스럽게 유료 전환을 안내할 수 있다.

또한 공간과 서비스를 짧은 시간 안에 경험할 수 있도록 1~2시간 중심의 집중 체험 프로그램이나 빠른 투어형 경험을 별도로 제공할 수 있다. 일반 무료체험 집단과 집중 체험 프로그램 제공 집단을 나누어 체류시간, 만족도, 재방문율 및 결제 전환율을 비교하고 실제 효과를 확인하는 것이 필요하다. 이러한 안내와 체험 프로그램을 적용했음에도 장ㄷ기 체류 비율이나 전환율에 변화가 나타나지 않는다면 이후 단계에서 1일 최대 체류시간 상한 도입을 추가로 검토할 수 있다.

- 기대 효과

체류 4시간 경과 시점에 멤버십 안내를 제공하면 장시간 이용 고객이 무료체험을 단순한 무상 업무 공간으로만 이용하는 것을 줄이고 이용 목적에 맞는 유료 상품을 적절한 시점에 안내할 수 있다. 또한 이용시간을 바로 제한하지 않기 때문에 고객의 선택권을 유지하면서 장기 체류 고객의 결제 전환 가능성을 확인할 수 있다.

1~2시간 중심의 집중 체험 프로그램은 고객이 짧은 시간 안에 공간과 핵심 서비스를 효율적으로 경험하도록 도와 체험 만족도를 높일 수 있다. 체험시간이 적절한 수준으로 분산되면 좌석과 공간의 회전율이 높아지고 특정 시간대에 장기 체류자가 집중되는 현상도 완화할 수 있다. 아울러 체류시간 정책을 단계별로 적용하고 결과를 측정하면 결제 전환과 관련된 적정 체류시간 기준을 구체화하고 향후 전환 예측 모델에 활용 할 수 있는 안정적인 행동 데이터를 확보할 수 있을 것으로 기대된다.

2) 시간대 기반 운영 전략

- 배경

분석 결과 저녁 시간대의 결제 전환율이 가장 높았고 오전과 오후 시간대는 상대적으로 낮았다. 다만 시간대별 방문 목적과 이용자 구성이 다를 수 있으므로 저녁 시간대에 방문한 사실 자체가 높은 전환율을 만든다고 단정하기는 어렵다. 저녁 방문자는 다른 시간대보다 비교적 짧고 집중적으로 공간을 이용하는 경향이 있어 시간대 자체보다는 체류시간과 이용 방식의 차이가 전환율에 함께 영향을 미쳤을 가능성이 있다.

- 제안

먼저 저녁 시간대를 기본 추천 체험 시간대로 노출한 집단과 노출하지 않은 집단을 구분하여 A/B테스트를 진행하고 실제 방문률과 결제 전환율에 차이가 발생하는지 확인할 필요가 있다.
방문자가 집중되지만 전환율으 상대적으로 낮은 오후 시간대 이용자에게는 체험 종료 후 다음 방문을 유도하는 리마인더와 멤버십 혜택 안내를 제공할 수 있다. 또한 무료체험 이용자가 몰리는 12시부터 17시 59분까지는 지점별 수용 가능 인원을 고려하여 체험 예약제, 시간대별 신청 인원 조정 또는 이용자가 많은 혼잡한 시간 안내를 시범적으로 적용하는 방안을 검토한다.

- 기대 효과

저녁 시간대 추천이 실제 전환율 개선으로 이어지는 검증함으로써 근거에 기반한 시간대 운영 정책을 수립할 수 있다. 오후 피크 시간대의 체험 수요가 다른 시간대로 분산되면 공간과 좌석의 과도한 집중을 완화하고 이용자에게 보다 안정적인 체험 환경을 제공할 수 있다. 또한 오후 방문자에 대한 후속 안내를 강화하면 상대적으로 낮은 전환율을 보이는 대규모 이용자 집단의 재망분과 결제 전환을 유도할 수 있다. 결과적으로 시간대별 운영 효율성과 공간 활용도를 높이고 이용 시간대에 따라 달라질 수 있는 고객 경험의 품질 편차도 줄일 수 있을 것으로 기대된다.

3) 재방문 유도 전략

- 배경

방문일수는 전환율과 강한 양의 상관관계를 가진 변수임이 확인되었다. 1일 방문 고객의 전환율은 34.0%였으나, 3일 방문 고객은 49.2%로 크게 상승하였다.
동시에 전체 유저의 53.9%(3,418명)가 하루만 방문하고 체험을 끝냈다. 가장 큰 집단이 가장 낮은 전환율을 보이고 있어, 개선 여지가 가장 크다고 볼 수 있다.
다만 방문 일수가 전환을 끌어올린 것인지, 애초에 결제 의향이 높은 유저가 더 자주 방문한 것인지는 본 분석으로 구분할 수 없다. 아래 제안은 이 방향을 실제로 확인하는 것을 겸한다.

- 제안

현재의 연속 3일 체험 방식을 일정 기간 안에는 원하는 3일로 선택하여 이용하는 방식으로 유연화하는 방안을 제시한다. 예를 들어 무료체험 신청 후 10일 이내에 이용자가 원하는 3일을 선택하도록 하면 개인 일정때문에 연속 방문이 어려운 고객도 체험 기회를 충분히 활용할 수 있다. 첫 방문이 종료된 이후에는 다음 방문 가능 일자와 남은 체험 횟수를 안내하는 리마인더를 자동으로 발송한다. 신청 후 아직 방문하지 않은 고객에게는 24시간 이내에 방문 일정 선택을 안내하고 2일 이상 방문한 고객에게는 첫 달 할인이나 멤버십 상담과 같은 전환 혜택을 제공하는 방안도 함께 검토할 수 있다. 이러한 정책은 한 번에 전면 도입하기보다 기존 방식과 비교하는 A/B 테스트를 통해 효과를 확인해야 한다.

- 기대 효과

체험 일정을 유연하게 선택할 수 있도록 하면 일정 문제로 방문을 포기하는 고객을 줄이고 무료체험 기간의 실제 활용률을 높일 수 있다. 재방문 과정에서 서로 다른 요일과 시간대 또는 지점을 경험하게 하면 고객이 공유오피스의 다양한 이용 방식을 확인하고 멤버십의 효용을 더 충분히 체감할 수 있다. 리마인더와 후속 혜택은 체험 과정이 중간에 끊기는 것을 줄이고 무료체험에서 유료 멤버십 안내까지 자연스럽게 연결하는 역할을 할 수 있다.

장기적으로는 재방문율과 전환율 변화를 함께 측정하여 효과적인 고객 접점과 안내 시점을 구체화 할 수 있을 것으로 기대된다.

4) 무료체험 설계 개선

- 배경

무료체험 신청자의 34.2%는 방문조차 하지 않았으며, 평균 방문일수는 1.63일에 불과했다. 이는 3일이라는 체험 기간이 실제 이용 패턴에 비해 길게 설계되었을 가능성을 시사한다.
다만 3일 모두 방문한 유저의 전환율이 49.2%로 가장 높았고(1일 방문 34.0%), 이는 결제 의향이 높은 유저가 더 자주 방문했을 가능성도 배제할 수 없다. 따라서 체험 기간을 줄이는 것이 전환율에 어떤 영향을 줄지는 본 분석만으로 판단하기 어렵다.
또한 미방문 신청자의 결제율도 35.5%로 방문자(39.2%)와 큰 차이가 없었다. 이는 무료체험 신청 시점에 이미 결제 의향이 있는 이용자가 상당 수 있을 가능성을 시사한다.

- 제안

무료체험 기간을 즉시 2일로 일괄 축소하기보다 기존 3일 체험과 2일 체험 또는 일정 기간 내 선택형 체험을 비교하는 A/B테스트를 진행할 필요가 있다. 신청 단계에서는 희망 방문일과 방문 목적을 간단히 선택하도록 하여 실제 방문 가능성이 높은 일정을 사전에 확보한다. 체험 시작 전에는 지점 위치, 이용 가능 시간, 제공 시설 및 준비사항을 안내하고 신청 후 일정 시간 동안 방문하지 않은 고객에게는 일정 변경이나 재예약 경로를 제공할 수 있다. 체험 중에는 무료 이용 자체만 안내하는 것이 아니라 유료 멤버십의 주요 혜택과 체험 중 이용한 서비스가 멤버십에서 어떻게 제공되는지를 설명하는 온보딩 메시지를 단계적으로 발송하는 방안도 제안한다.

- 기대 효과

신청 단계에서 방문 일정을 확정하면 단순 관심으로 신청한 고객과 실제 방문 의향이 있는 고객을 구분하고 방문 비율을 줄이는 데 도움이 될 수 있다. 체험 기간과 운영 방식을 비교하는 실험을 통해 고객 경험을 훼손하지 않으면서도 가장 효율적인 무료체험 기간을 확인할 수 있다. 또한 방문 안내와 일정 변경 기능을 제공하면 신청 이후 체험이 시작되지 못하는 상황을 줄이고 무료체험 운영에 투입되는 불필요한 비용을 낮출 수 있다. 멤버십 혜택을 체험 과정과 연결해 안내하면 고객이 무료 이용과 유료 서비스의 차이를 명확하게 이해하고 체험 경험이 결제로 이어지는 전환 경로를 보다 자연스럽게 형성할 수 있을 것으로 기대된다.

5) 지점 운영 전략

- 배경

지점별 전환율은 34.0%~44.2%로 10.2%p의 표면적 차이가 있으나, 이 차이는 지점의 물리적 특성으로 인한 차이로 보기는 어렵다.
복수 지점을 이용한 이용자의 전환율은 49.5%로 단일 지점 이용자(38.8%)보다 10.7%p 높았다.
다만 복수 지점 이용자는 281명(4.4%)에 불과하며, 여러 지점을 이용해서 전환한 것인지 원래 적극적인 이용자가 여러 지점을 이용한 것인지는 본 분석으로 구분하기 어렵다.

- 제안

전 지점에 적용할 수 있는 기본 서비스 품질 기준을 수립하고 좌석·시설·안내·청결·응대 등 공통 운영 항목을 동일한 기준으로 관리할 필요가 있다. 신규 지점은 존 지점과 같은 전환율 기준으로 바로 평가하지 않고 운영일수와 누적 이용자 수를 고려한 별도의 초기 관리 지표를 적용한다. 저전환 지점은 단순히 전환율만 비교하기보다 방문자의 체류시간, 이용 시간대, 주말 이용 비율, 재방문율 및 이용자 구성 등을 함께 확인하여 전환율이 낮게 나타난 원인을 먼저 파악해야 한다. 복수 지점 이용자의 전환율이 높게 나타난 결과를 바탕으로 이용자가 체험 기간 동안 서로 다른 지점을 선택할 수 있는 네트워크형 체험도 시범적으로 운영할 수 있다. 다만 원래 결제 의향이 높은 고객이 여러 지점을 방문했을 가능성이 있으므로 단일 지점 체험군과 복수 지점 체험군을 비교하여 효과를 검증해야 한다.

- 기대 효과

공통 서비스 기준을 적용하면 지점에 따라 달라질 수 있는 체험 품질을 줄이고 고객에게 일관된 브랜드 경험을 제공할 수 있다. 신규 지점에 별도 지표를 적용하면 운영 초기의 작은 표본으로 인해 전환율이 과도하게 높거나 낮게 평가되는 문제를 완화할 수 있다. 저전환 지점의 이용자 구성과 행동 특성을 함께 모니터링하면 지점 자체의 문제와 방문자 구성에 따른 차이를 구분하여 필요한 영역에 자원을 투입할 수 있다. 또한 네트워크형 체험이 효과적인 것으로 확인되면 고객이 여러 지역에서 동일한 멤버십을 활용할 수 있다는 장점을 직접 경험하게 하여 공유 오피스 멤버십의 효용을 높일 수 있을 것으로 기대된다.

3. 한계점

1) 무료체험 신청 수 대비 낮은 실제 방문 수

무료체험 신청자 9,624명 중 34.2%는 한 번도 방문하지 않은 것으로 나타났다. 방문 여부는 전환율에 영향을 주지만, 방문하지 않아도 결제하는 이용자가 상당수 존재한다는 점은 3일이라는 무료체험 기간이 비효율적으로 길게 설계된 구조일 수 있음을 시사한다.

본 프로젝트에서는 무료체험 신청자 중 실제 방문한 유저를 대상으로 분석을 진행하였기에 추후 방문 여부 및 무료체험 기간별 결제 전환율 예측에 대한 추가 분석을 진행할 필요성이 있다.

2) 결제 시점 데이터 부재

현재 데이터에는 최종 결제 여부만 존재하고 이용자가 언제 결제를 완료했는지에 대한 정확한 시점 정보가 없다. 따라서 무료체험 이용행태가 결제 이전에 발생한 것인지, 이미 결제를 결정하거나 완료한 이용자가 이후에도 방문한 것인지 명확하게 구분하기 어렵다.

특히 체류시간과 방문일수가 많을수록 결제 여부가 달라지는 결과가 나타났지만 이를 이용행태가 결제를 유도한 인과효과로 해석해서는 안된다. 향후에는 결제 일시와 멤버십 시작일 데이터를 확보하여 결제 이전의 방문 행동만으로 모델을 구성하고 이용행태와 결제 전환의 시간적 선후관계를 확인할 필요가 있다.

3) 지점별 운영 환경 변화 반영의 어려움

지점별 운영기간과 오픈 시점뿐만 아니라 프로모션, 가격 정책, 시설 변경, 특수 이벤트, 휴무 및 운영시간 변화 등이 방문 수요와 결제 전환율에 영향을 미쳤을 가능성이 있다. 그러나 이러한 운영 이력 데이터가 제공되지 않아 지점별 전환율 차이에서 운영 환경의 영향을 분리하여 통제하지 못했다.

따라서 지점별 전환율이 34~44%로 다르게 나타났더라도 이를 지점 서비스 품질의 차이로 단정하기 어렵다. 향후에는 지점별 운영기간, 프로모션 시행 여부, 가격 정책, 시설 구성 및 이벤트 정보를 시점별로 관리하고 모델 변수로 반영할 필요가 있다.

4) 이용도 등급 매칭 방식의 근사치 한계

2차 결제 전환 모델에서는 여러 방문 기록을 유저별 1행으로 집계하기 위해 주 이용 지점과 주 이용 시간대를 최빈값으로 설정하고 대표 체류시간은 중앙값으로 산출하였다. 이후 유저의 첫 방문 날짜와 최빈 지점·시간대를 기준으로 1차 모델에서 생성한 이용도등급을 매칭하였다.

그러나 최빈 지점과 시간대가 실제 첫 방문 당시의 지점 및 시간대와 다를 수 있고 동일 이용자가 여러 날짜와 시간대에 경험한 이용도 수준의 차이도 하나의 등급으로 단순화된다. 따라서 level_idx는 이용자가 체험한 실제 동시 체류 환경을 완벽하게 나타내는 값이 아니라 대표적인 이용 수준을 근사한 변수로 해석해야 한다. 향후에는 방문별 이용도 등급의 평균, 최댓값, 고수요 경험 횟수 및 이용도 등급 변화량 등을 추가로 활용 할 필요가 있다.

5) 유료 회원 이용 데이터 부재

동시 체류 인원은 무료체험 이용자의 방문 기록만으로 산출하였다. 실제 공유오피스에는 기존 유료 회원도 함께 체류하고 있지만 유료 회원의 입·퇴실 기록은 제공되지 않았다. 따라서 본 분석에서 산출한 동시 체류인원과 이용도 등급은 공간 전체의 이용도가 아니라 무료체험 이용자만을 기준으로 한 수요 수준이다.

이에 따라 이용도가 '높음'으로 분류된 시간대라도 실제 공간 전체가 혼잡했다고 단정할 수 없으며 반대로 무료체험 이용자가 적더라도 유료 회원이 많아 실제 공간은 혼잡했을 가능성이 있다. 향후에는 유료 회원의 출입 기록과 좌석 수, 회의실 이용률 등의 데이터를 함께 활용하여 전체 공간 이용도를 측정해야 한다.

6) 결제 전환 예측 모델 성능의 제한

최종 결제 전환 예측 모델의 AUC는 약 0.64로, 결제 고객과 미결제 고객을 구분하는 능력이 제한적인 수준이었다. 이는 모델이 결제 전환과 관련된 일부 행동 신호를 포착했지만 개별 이용자의 결제 여부를 정확하게 판단하거나 자동화된 개인화 추천에 바로 활용하기에는 충분하지 않다는 것을 의미한다.

따라서 본 모델은 결제 여부를 확정적으로 판단하는 도구보다 체류시간과 재방문 여부 등 전환과 관련된 주요 행동 특성을 탐색하고 마케팅 대상군을 넓게 선별하는 보조 수단으로

활용하는 것이 적절하다. 향후에는 신청 목적, 유입 경로, 직업, 이용 목적, 멤버십 관심도 등의 변수를 추가하여 예측력을 개선할 필요가 있다.

7) Train/Test 기간 간 결제 전환율 차이

모델은 실제 미래 예측 상황을 반영하기 위해 2023년 9월 1일을 기준으로 이전 기간을 Train, 이후 기간을 Test 데이터로 분리하였다. 그러나 두 기간의 결제 전환율은 각각 41.2%와 27.2%로 14.0%p 차이를 보였다. 이는 학습 기간과 검증 기간 사이에 이용자 구성이나 운영 정책, 시장 환경이 달라졌을 가능성을 보여준다.

이러한 분포 변화로 인해 과거 데이터에서 학습한 패턴이 이후 기간에 동일하게 적용되지 않았고 모델 성능에도 영향을 미쳤을 가능성이 있다. 단순히 무작위 분할로 변경하면 성능 수치는 높아질 수 있지만 미래 데이터 예측이라는 현실적인 조건을 반영하지 못할 수 있다. 따라서 향후에는 시점을 이동해가며 반복 검증하는 시계열 교차검증을 적용하고 기간별 전환율과 주요 변수의 분포 변화를 함께 모니터링 할 필요가 있다.

8) 과거 데이터 기반 예측의 한계

본 분석에서는 2021년 5월부터 2023년 12월까지의 데이터가 사용되었다. 그러나 해당 기간 이후 공유오피스의 가격, 무료체험 정책, 지점 운영 방식, 고객 구성 및 외부 시장 환경이 달라졌을 가능성이 있다. 관련 정책 및 외부 요인 데이터가 없어 이러한 변화가 수요와 결제 전환에 미치는 영향을 모델에 반영하지 못했다.

따라서 과거 이용 패턴만으로 학습한 모델이 현재 또는 미래의 운영 환경에서도 동일한 성능을 유지한다고 보장할 수 없다. 실제 운영에 활용할 경우 최근 데이터를 지속적으로 추가하여 모델 성능과 변수 분포를 점검하고 일정 주기마다 모델을 재학습해야 한다. 또한 정책 변경이나 프로모션 시행 시점을 별도 변수로 관리하여 환경 변화에 따른 영향을 구분할 필요가 있다.

부록

2차 모델링

1. 관계 구조 탐색 **–** 첫 방문 이용도**,** 재방문 여부와 결제 전환

'혼잡한 시간대에 체험한 유저일수록 재방문을 포기하고, 그 재방문 포기가 결제 실패로 이어지는 것 아닌가?' 라는 가설을 세우고 이를 두 단계로 나눠 직접 검증했다: 1단계는 '이용도(이용도 등급)가 재방문 포기에 영향을 주는가', 2단계는 '재방문 포기가 결제 전환에 영향을 주는가'이다.

① **1**단계 **—** 이용도**(**첫 방문 등급**)**가 재방문 포기에 영향을 주는가

첫 방문 등급(수요없음/보통/높음)별로, 3일 체험 기간 중 단 하루만 방문하고 다시 오지 않은 유저의 비율(재방문 포기율)을 비교했다.

[표 **Appendix-1]** 이용도 등급별 재방문 포기율

첫 방문 등급	재방문 포기율
높음	55.3%
보통	52.1%
수요 없음	54.2%

카이제곱 검정 결과 p-value=0.0545로, 일반적인 유의수준(0.05) 기준에서는 통계적으로 유의하다고 보기 어려웠다(다만 경계선에 아주 근접했다). 등급 간 포기율 차이도 3%p 안팎으로 크지 않았고, '높음' 등급의 포기율이 '보통'보다는 높았지만 '수요 없음'도 그 사이 어딘가에 있어 등급이 오를수록 포기율도 단조롭게 올라가는 깔끔한 패턴은 아니었다. 즉 '이용도 → 재방문 포기' 연결고리는 데이터상 뚜렷하게 확인되지 않는, 약하고 불확실한 신호로 판단했다.

② **2**단계 **—** 재방문 포기가 결제 전환에 영향을 주는가

이번에는 방향을 바꿔, 재방문을 포기한 유저와 재방문한 유저 사이에 실제 결제 전환율 차이가 있는지, 그리고 방문일수가 늘수록 전환율이 어떻게 달라지는지 확인했다.

[표 **Appendix-2]** 재방문 포기 여부에 따른 결제 전환율

구분	결제 전환율
재방문 포기(1일만 방문)	33.9%

재방문(2일 이상 방문)	45.4%

재방문 포기 유저(33.9%)와 재방문 유저(45.4%) 사이의 전환율 차이는 11.5%p로 뚜렷했다. 방문일수별로 더 세분화해서 봐도 1일→2일→3일로 갈수록 전환율이 거의 선형적으로 상승하는 일관된 패턴이 확인되어, '재방문 포기 → 전환 실패' 연결고리는 1단계와 달리 매우 강한 신호로 나타났다.

③ 모델 재검증 **(Base + level_idx vs Base + level_idx + dropout, RF)**

통계적 검정만이 아니라 실제 예측 모델에 dropout 변수를 추가했을 때도 성능이 뚜렷하게 개선되는지 다시 확인했다.

[표 **Appendix-3] Random Forest** 모델 재검증 결과**: dropout** 변수 추가

변수 구성	**Macro F1**	**Balanced Accuracy**	**AUC**	재현율 **(**결제**)**	정밀도
Base + level_idx	0.569	0.603	0.627	0.607	0.361
Base + level_indx + dropout	0.580	0.600	0.640	0.545	0.372

④ 결론

dropout(재방문 여부) 변수를 추가했을 때 Random Forest의 정확도가 62.7%에서 64.0%으로, Macro F1이 56.9%에서 58.0%로 개선되었다. 하지만 재현율은 오히려 60.7%에서 54.5%로 감소하였으며 재방문 포기만으로는 결제 전환을 예측하는데 한계가 있음을 확인했다. 이에 따라 새로운 변수를 추가하여 모델 성능 개선을 다시 시도해보았다.

2. 추가 개선 시도

① 새 독립변수 추가 **(Base + level_idx** 기준**, RF)**

기존 base+level 모델에 세 가지 후보 변수를 하나씩 추가해가며 효과를 확인했다.

register_lag_days는 신청일과 실제 방문일 사이의 간격으로, 신청 후 바로 오는 유저와 한참 있다 오는 유저의 결제 성향이 다를 수 있다는 가정에서 추가했다.

multi_site는 한 유저가 여러 지점을 이용했는지 여부로, 여러 지점을 다녀본 유저일수록 서비스에 더 익숙하거나 관심도가 높을 것이라는 가정이었다.

dropout은 방문 첫날 이후 재방문하지 않고 이탈한 유저인지를 나타내는 변수로, 앞선 인과 사슬 분석에서 전환과 가장 강하게 연결된 것으로 확인된 변수다.

[표 **Appendix-4]** 추가 변수에 따른 모델 성능 비교표

모델	**Macro F1**	**AUC**
Base + level_idx	0.569	0.626
+ register_lag_days	0.574	0.631
+ multi_site	0.560	0.625
+ dropout(재방문 안함)	0.581	0.640

새로운 변수 3개를 각각 추가하여 모델 성능 변화를 비교하였다. `register_lag_days`(신청일과 방문일 간격)를 추가한 경우 Macro F1은 0.569에서 0.574로, AUC는 0.626에서 0.631로 소폭 개선되었다. 반면 `multi_site`(여러 지점을 이용했는지 여부)를 추가했을 때는 Macro F1이 0.569에서 0.560로, AUC가 0.626에서 0.625으로 오히려 소폭 감소하였다.

`dropout`(1일만 방문하고 이후 재방문하지 않은 경우)을 추가했을 때는 Macro F1이 0.569에서 0.581로, AUC가 0.626에서 0.640로 향상되었다. 이를 통해 기존 변수만으로는 포착하기 어려웠던 재방문 여부가 결제 여부를 설명하는 데 추가적인 정보를 제공하는 변수임을 확인하였다.

② 하이퍼파라미터 튜닝

모델 구조를 바꾸지 않고도 세부 설정값(트리 개수, 깊이, 학습률 등)을 최적화하면 성능이 오를 수 있다는 가정하에, RandomizedSearchCV로 XGBoost의 하이퍼파라미터를 자동 탐색했다. 기본값으로 학습한 RandomForest(base+level_idx)를 기준선으로 놓고 비교했다.

[표 **Appendix-5]** 하이퍼파리미터 튜닝 전후 모델 성능 비교표

설정	**Macro F1**	**AUC**
튜닝 전(기본 값, RF)	0.569	0.627
튜닝 후 (RandomizedSearchCV, XGB)	0.591	0.613

XGBoost의 하이퍼파라미터 20가지 조합을 RandomizedSearchCV를 통해 탐색한 결과, subsample=0.6,n_estimators=300, max_depth=3, learning_rate=0.03, colsample_bytree=0.6 조합에서 가장 높은 Macro F1 0.591을 기록하였다.

기준 모델인 base+level Random Forest와 비교하면 Macro F1은 0.569에서 0.591로 소폭 향상되었으나, AUC는 0.627에서 0.613으로 감소하였다. 따라서 하이퍼파라미터 조정을 통해 특정 평가 지표는 개선할 수 있었지만, 전체적인 분류 성능이 일관되게 향상되지는 않았으며 모델의 설정값만을 변경하는 것에는 성능 개선의 한계가 있음을 확인하였다.

③ 다른 모델군 비교 **(base+level** 기준**)**

특정 모델 계열의 한계일 가능성을 배제하기 위해, 트리 기반 모델(RandomForest, XGBoost, LightGBM, GradientBoosting)뿐 아니라 계열이 전혀 다른 로지스틱회귀, SVM, 신경망(MLP)까지 동일한 base+level 변수 조합으로 학습해 비교했다.

[표 **Appendix-6]** 모델별 성능 비교표

모델	**Macro F1**	**AUC**
RandomForest	0.569	0.626
신경망(MLP)	0.548	0.616
로지스틱회귀	0.537	0.614
SVM	0.537	0.613
LightGBM	0.542	0.593
GradientBoosting	0.555	0.585

서로 다른 6가지 분류 모델을 비교한 결과, AUC가 0.585~0.627 범위에 분포했으며 Random Forest가 0.627로 가장 높고 Gradient Boosting이 0.585로 가장 낮았다. 모델별 성능 차이는 존재하지만 전체적으로 AUC가 유사한 범위에 머물렀다는 점에서, 현재의 낮은 예측 성능이 특정 모델 선택의 문제라기보다는 데이터에 포함된 변수 자체의 설명력과 관련이 있을 가능성을 확인하였다.

④ 임계값**(threshold)** 조정 **(RF, base+level** 기준**)**

모델 자체의 판단 능력(AUC)은 한계가 뚜렷했지만, 결제 여부를 나누는 확률 기준선(threshold)을 낮추면 '결제할 가능성이 있는 유저를 더 폭넓게 잡아내는' 방향으로 운용할 수 있으므로, 기본값 0.5에서 0.4, 0.35, 0.30까지 낮춰가며 재현율과 정밀도의 변화를 확인했다.

[표 **Appendix-7]** 임계값별 모델 성능 비교표

기준**(threshold)**	재현율**(**결제**)**	정밀도**(**결제**)**
0.50	60.7%	36.1%
0.40	90.2%	29.6%
0.35	94.7%	27.4%
0.30	99.6%	27.2%

기준값을 0.50에서 0.40으로 낮추면 결제 고객을 놓치지 않는 비율인 재현율이 60.7%에서 90.2%로 크게 증가한다. 반면 결제할 것으로 예측한 고객 중 실제 결제 고객의 비율인 정밀도는 36.1%에서 29.6%로 감소한다. 기준값을 0.30까지 낮추면 재현율은 99.6%까지

높아지지만 정밀도는 27.2%로 낮아져, 결제 가능성이 낮은 고객까지 결제 대상으로 많이 포함하게 된다.

따라서 결제 가능 고객을 최대한 놓치지 않는 것이 중요한 마케팅 활용 목적이라면 threshold 0.40을 적용하는 방안을 고려할 수 있다. 반면 오예측을 줄이고 정밀도를 상대적으로 높이는 것이 중요하다면 threshold 0.50을 사용할 수 있다.